글로벌 흥행 콘텐츠의 공식:

TMDB-IMDb 영화·드라마 데이터 분석 프로젝트

6조_육개장 4인분

김승윤, 김인표, 윤예원, 차지연

2025. 12. 30.

목차

01 프로젝트 개요

02 데이터 확보

03 성과 지표 산출

04 EDA

05 데이터 분석

06 머신러닝

07 결론

08 대시보드 제작

01

프로젝트 개요 배경 및 문제 정의

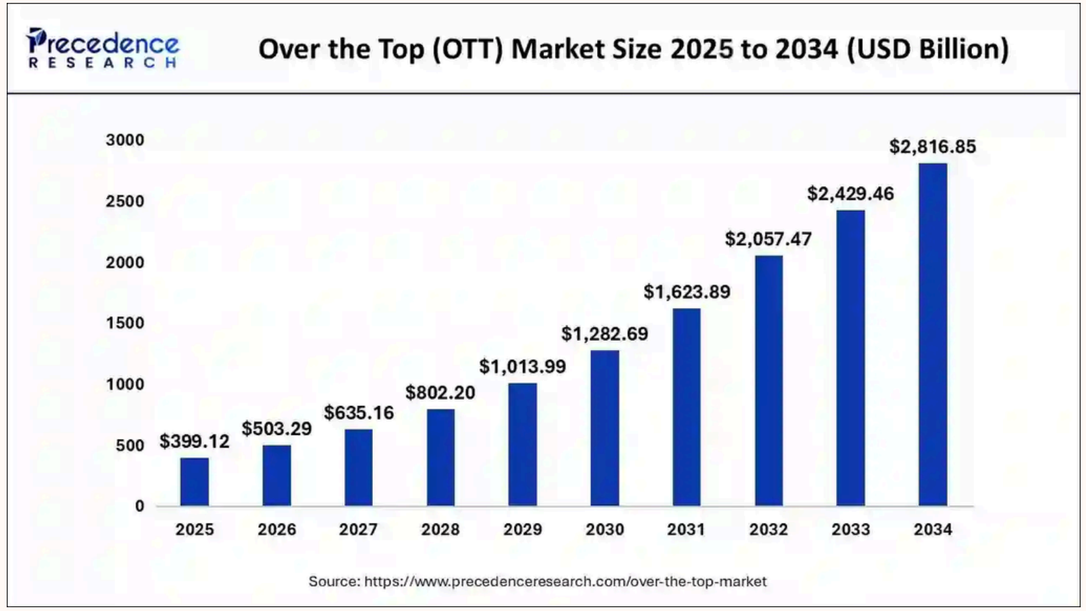

- 현재 글로벌 OTT 시장은 넷플릭스·아마존 중심으로 약 4천 억 달러, 2034년 2.8조 달러로 **고성장 전망**
- 시장은 확대되었으나, 성숙 시장에서 **가입자 증가 둔화·해지율 상승**
- 이에 따라 구독 수익성 확보를 위한 **경쟁 심화**

→ **흥행 가능성 높은 콘텐츠 선별·기획 역량**이 OTT 핵심 경쟁력

* OTT(Over-The-Top): 기존 케이블 TV나 셋톱박스 같은 전통 방송망을 거치지 않고 인터넷을 통해 영화, 드라마, 방송 등 미디어 콘텐츠를 직접 제공하는 서비스

01

프로젝트 개요 주제 및 목표

프로젝트 목적 | 글로벌 영화·드라마 콘텐츠의 흥행 패턴과 핵심 특성을 데이터로 분석해, OTT 관계자에게 콘텐츠 제작과 투자 판단 기준을 제공

프로젝트 주제 | 글로벌 영화·드라마의 흥행작 특성을 파악하고, 흥행 기준을 제시하여, 흥행 예측 모델 개발

프로젝트 기간 | 2025.11.24. - 2025.12.28.

프로젝트 결과물

흥행점수 및 흥행 콘텐츠 예측 모델
인사이트 및 비즈니스 솔루션
Streamlit 기반 인터랙티브 분석 시스템

01

프로젝트 개요 분석 내용

흥행 키워드

흥행 콘텐츠 특징을
흥행 콘텐츠의 어휘
특징으로 구체화

흥행 서사 도출

서사 토픽 모델링을
통해 흥행 콘텐츠의
서사적 특징을 파악

리뷰 범주화

리뷰 범주화로
사용자의 반응을
이끌어낸 콘텐츠의
요소 구체화

흥행 예측 모델

트리 기반 모델과
신경망 모델을 통해
흥행을 미리 예측할
수 있는 모델 개발

02

데이터 확보 데이터 수집

TMDb API

TMDb에서 제공하는 공식 API를 통해 수집

다양한 영화/드라마 메타 데이터 제공

사용자의 기여를 통해 데이터가 기입되므로 일부 정보가 구체적이지 않음

리뷰 데이터 부족

IMDb 크롤링

IMDb 사이트에서 크롤링

방대한 영화/드라마 메타 데이터와 리뷰 데이터 제공

공식 API가 없어 수집에 어려움

평점 작성기준이 까다로워 구체적인 리뷰 수집 가능

02

데이터 확보 데이터 전처리

1	2	3	4
필요 컬럼 선정	카테고리 통합	다중 속성 분리 및 정규화	최종 데이터셋
결측값 대체 불가능 OR 불필요한 컬럼 삭제	범주 수가 과도한 카테고리 정제 및 통합	다중속성 컬럼 분리 및 테이블 정규화	최종 데이터셋 구성 및 분석 시작

02

데이터 확보 최종 데이터셋

구분	영화 데이터	드라마 데이터
데이터 기간	2005년 1월 1일 ~ 2025년 11월 30일 (약 21년 간)	
데이터 규모	약 26,000편	약 3,000편
성과 데이터	평점 수, 평점	
서사 데이터	줄거리, 장르	
리뷰 데이터	IMDb 리뷰 텍스트 * IMDb ID를 식별자로 TMDB 데이터와 결합	
플랫폼 데이터	OTT 구독 플랫폼 정보	
수익·비용 데이터	제작비 / 수익 정보 (일부)	없음
기타 메타데이터	개봉일, 러닝타임, 제작 언어/국가 등	방영 시작일, 시즌 정보, 제작 언어/국가 등

03

성과 지표 산출 흥행점수 계산

질적 지표 양적 지표

(50% + 50%) × 100%

리뷰 감성 점수

시청자의 리뷰에서 드러나는
정성적 평가의
리뷰 평가 중심 가중 평균

평점

시청자가 자신의 시청 후기를
10점 만점의 정량적 척도에
표기한 점수

평점 개수

관객 정보를 대신해 정량적
흥행 지표를 로그값으로 사용

03

성과 지표 산출

흥행점수 분포

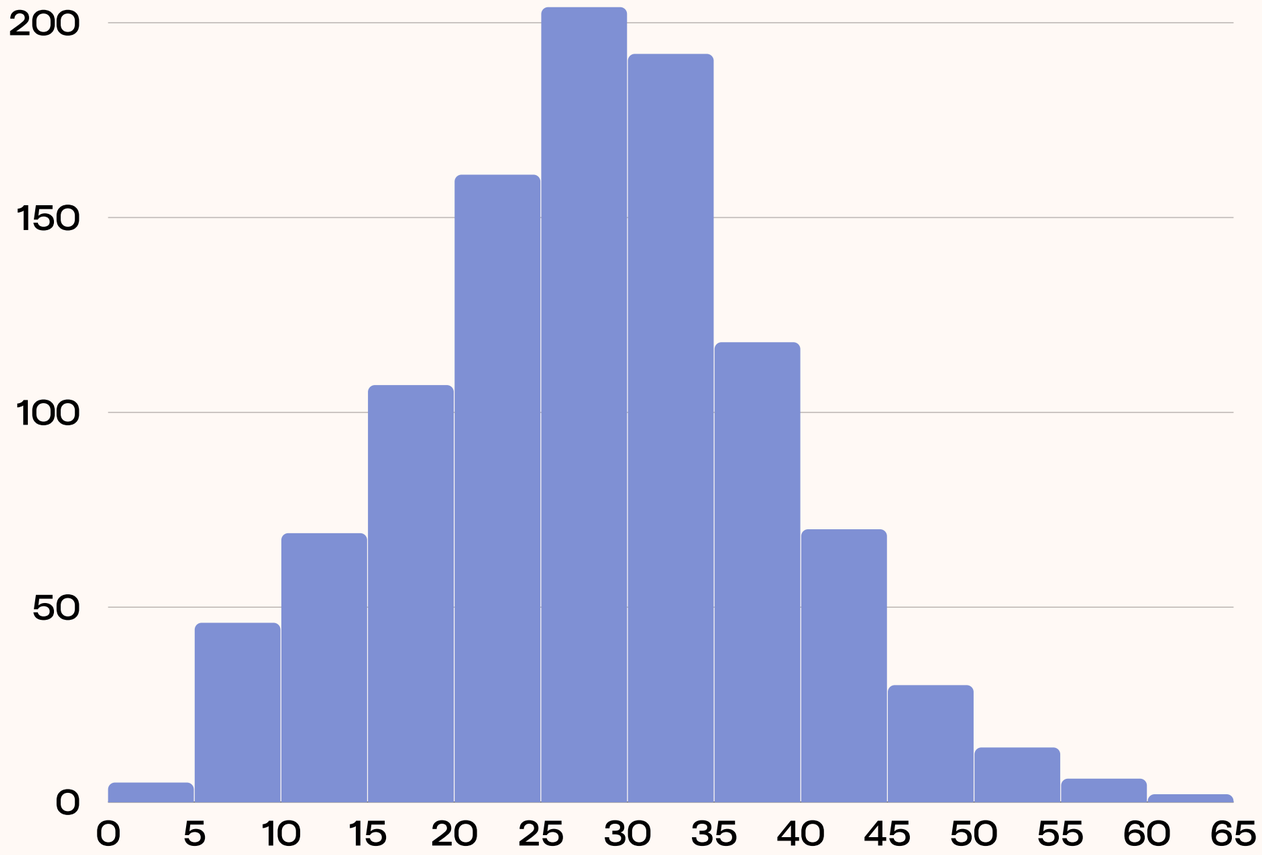

흥행작 : 상위 20%

비흥행작 : 하위 40%

- 최종 그래프는 정규 분포에 가깝지만 비틀린 모양
- **흥행작**은 파레토 법칙에 따라 **상위 20%** 라고 가정
- **비흥행작**은 데이터 삭제 최소화 및 예측 모델 성능 향상을 위해 **하위 40%**로 정의

* 파레토 법칙: 전체 시장의 상위 20%가 나머지 80%를 차지한다는 원리

04

EDA 국가별 흥행 비중

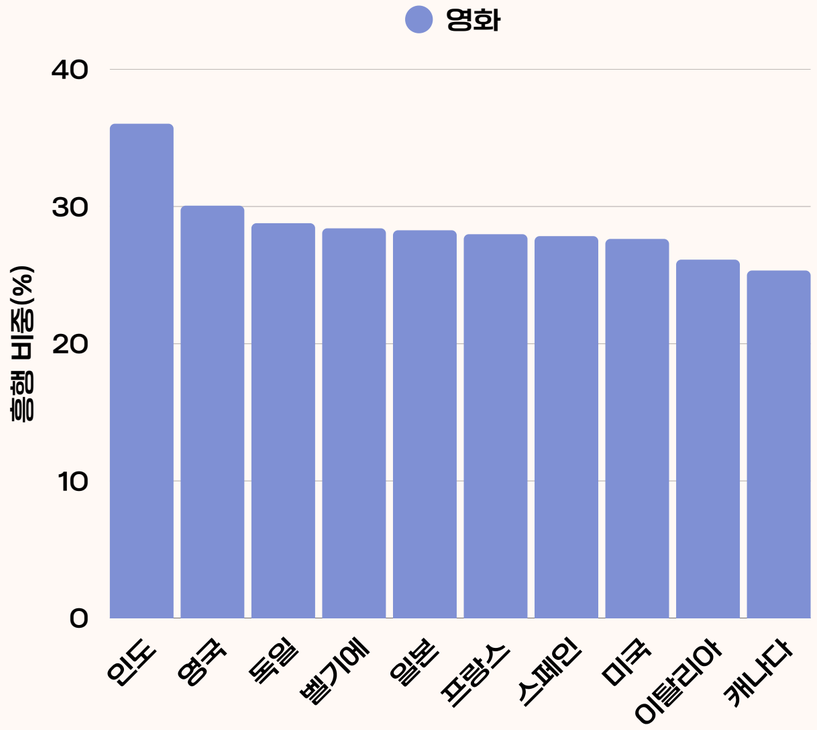

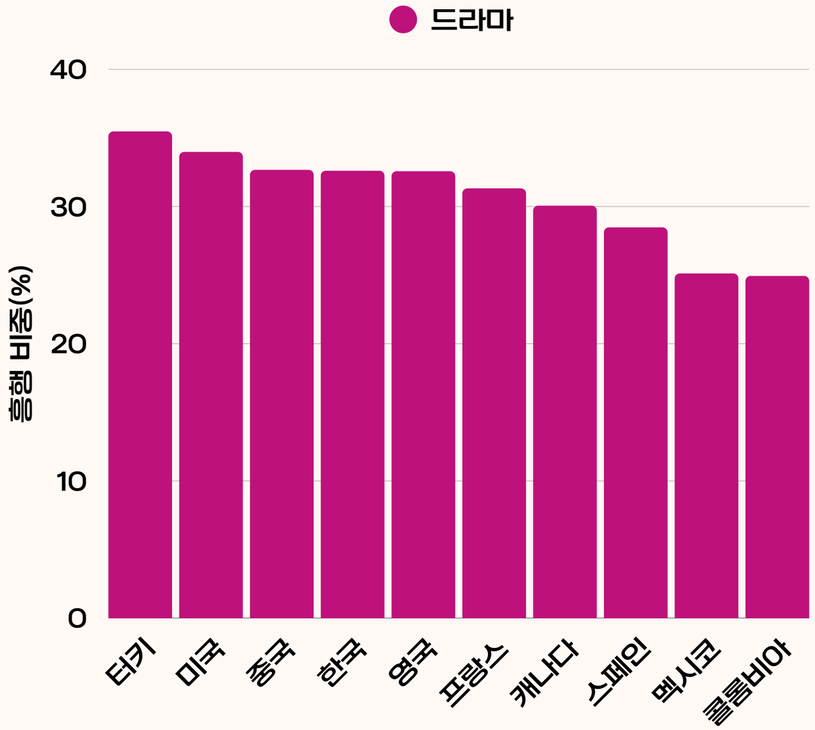

- **국가별 흥행점수가 유사**하나 인도가 높게 나온 편
- 인도 영화가 해외 수출되는 경우 등록됐을 수 있음

- 미국을 제외하고 **아시아권이 상위권**에 위치
- 유럽 및 아메리카 지역은 비교적 하위에 위치

04

EDA OTT별 흥행 비중

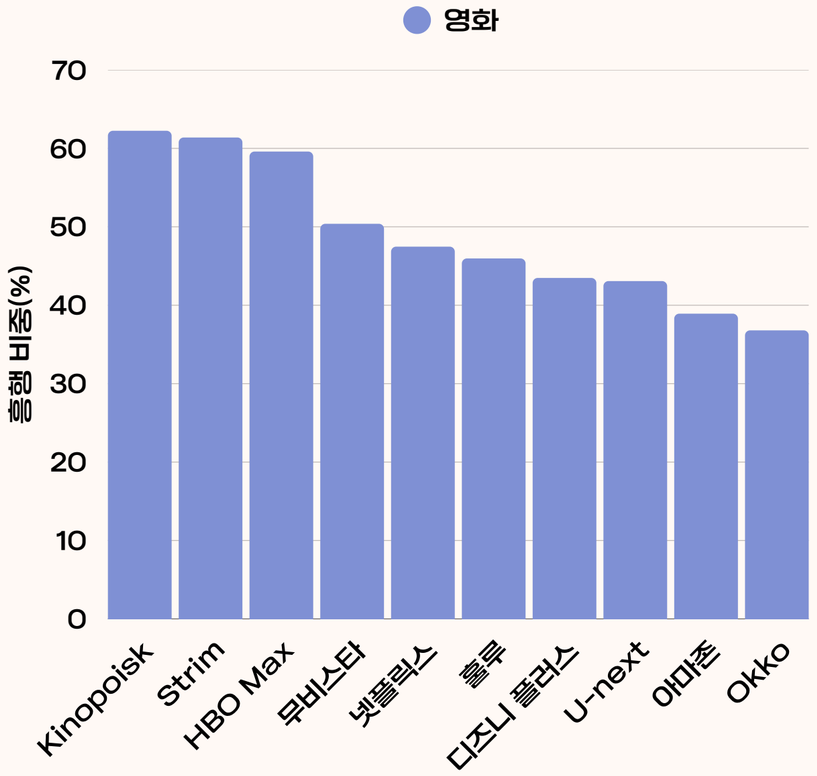

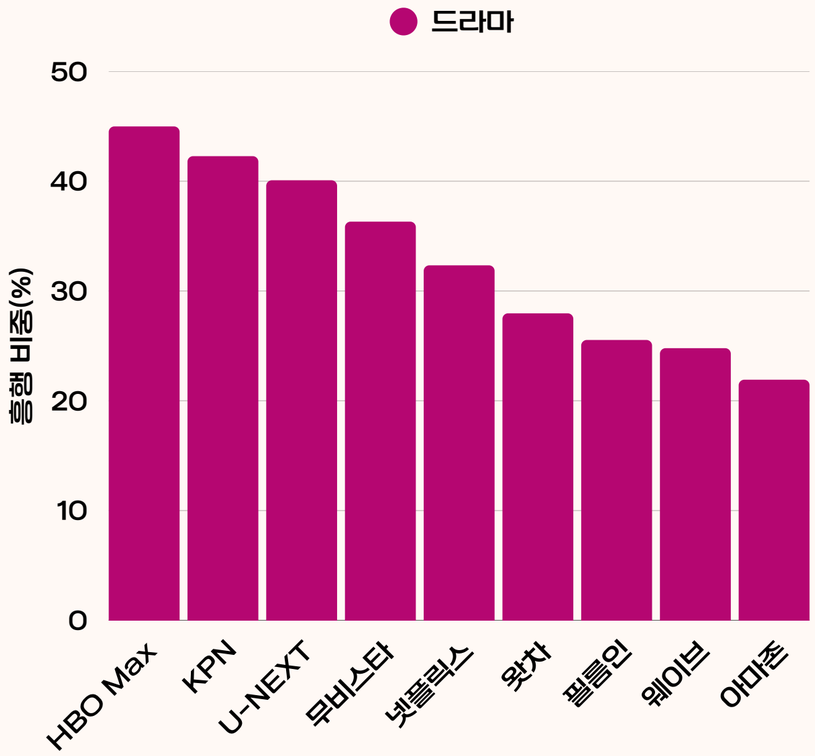

- **거대 OTT 기업의 흥행작 비율은 낮은 편** → 여러 영화/드라마를 동시에 가지고 있기 때문일 것으로 예상
- **소규모 OTT는 흥행작 위주 확보 전략**을 취하는 것으로 보임

05

데이터 분석 장르별 흥행 비율

영화

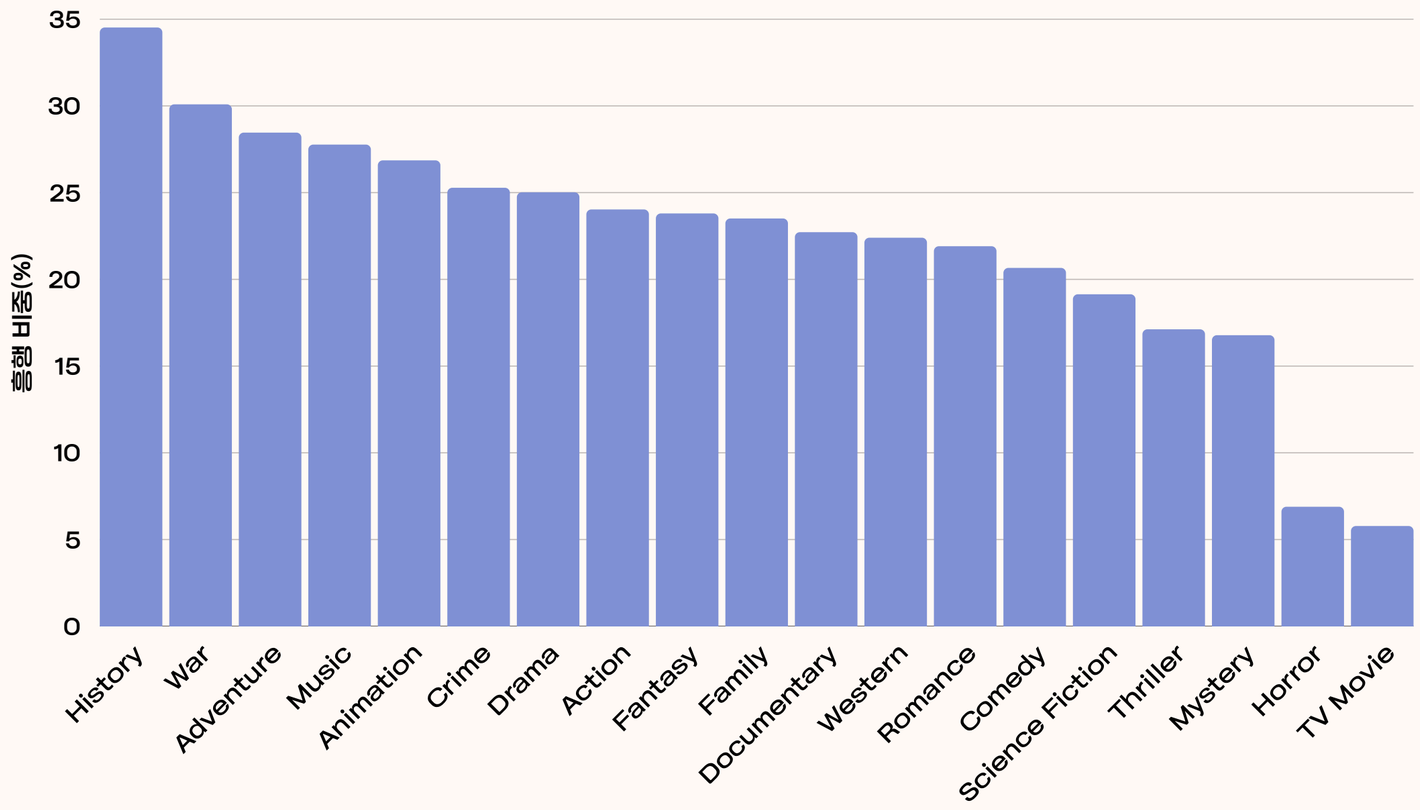

카이제곱 검정 결과

P-value : 0.00***
Cramér's V: 0.1459
통계적으로 유의

- 장르에 따른 흥행 비율 차이는 **유의미**
- 역사, 전쟁 등 거대 **서사 관련** 장르에서 **흥행율 ↑**
- **공포, TV Movie 장르**에서 **흥행율 ↓**

* 카이제곱 검정: 각 범주의 영향이 서로 독립인지 검정하는 통계적 방법

05

데이터 분석 장르별 흥행 비율

드라마

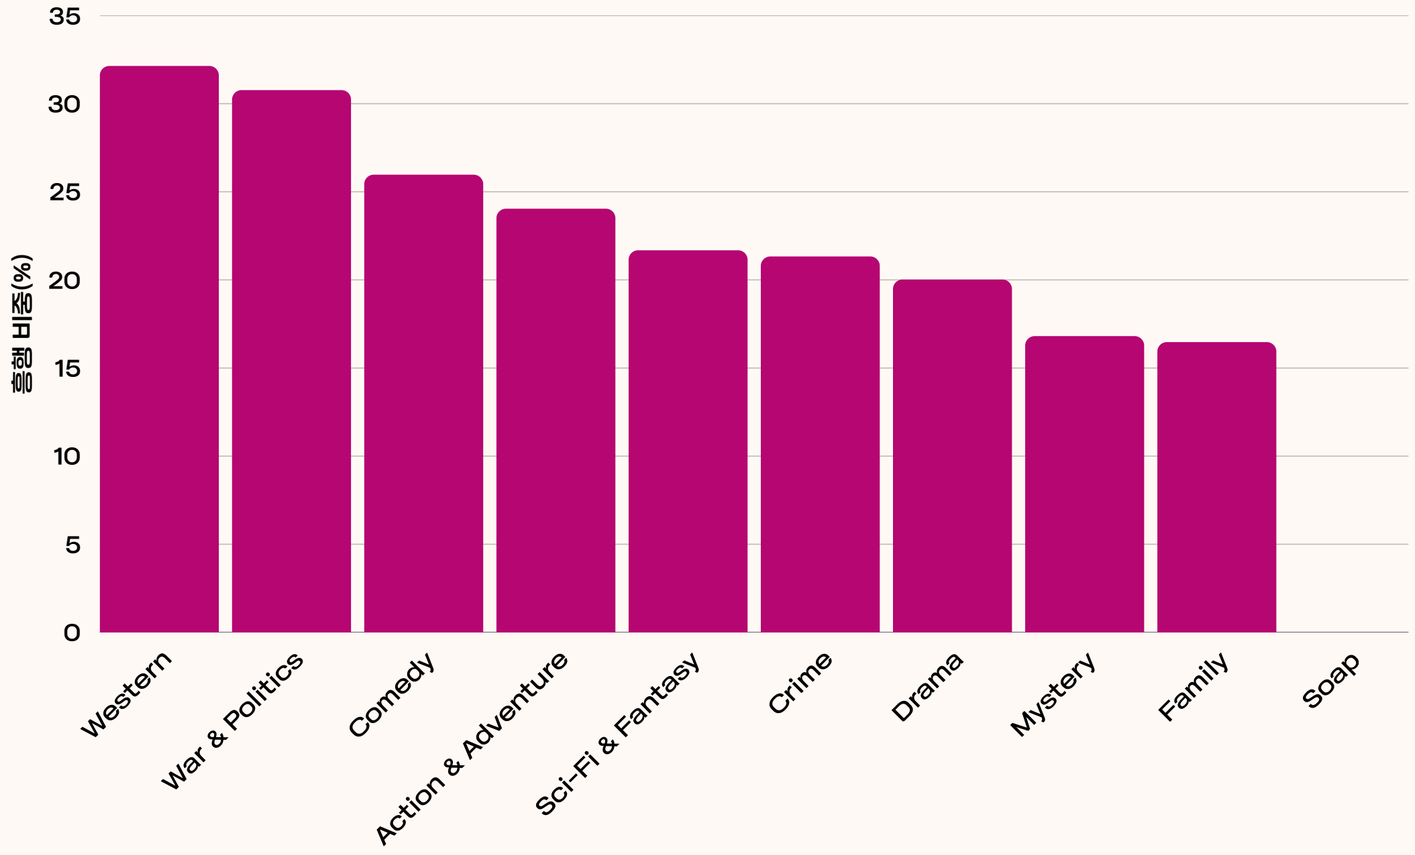

카이제곱 검정 결과

P-value : 0.00***
Cramér's V: 0.1813
통계적으로 유의

- 장르에 따른 흥행 비율 차이는 **유의미**
- 소프 드라마처럼 **일상 반복 구조**의 장르가 거의 흥행하지 않는 것이 특징

* 소프 드라마(Soap Opera): 아침 드라마나 일일 드라마와 형식·특징이 매우 유사한 해외 연속극 장르

05

데이터 분석 줄거리 키워드 분석

흥행 vs 비흥행 영화 델타 TF-IDF

갈등과 변화 중심 어휘

진중한 서사 중심

- 흥행작은 **갈등과 변화 중심** 어휘가 자주 등장
- 전쟁 등 **진중한 서사**나 액션 서사가 많음
- 비흥행작은 **공간이나 관계 중심 어휘**가 많음

* 델타 TF-IDF: 긍부정의 TF-IDF의 차를 구하여 양 집단의 대표 키워드를 확인하는 방법

05

데이터 분석 줄거리 키워드 분석

흥행 vs 비흥행 드라마 델타 TF-IDF

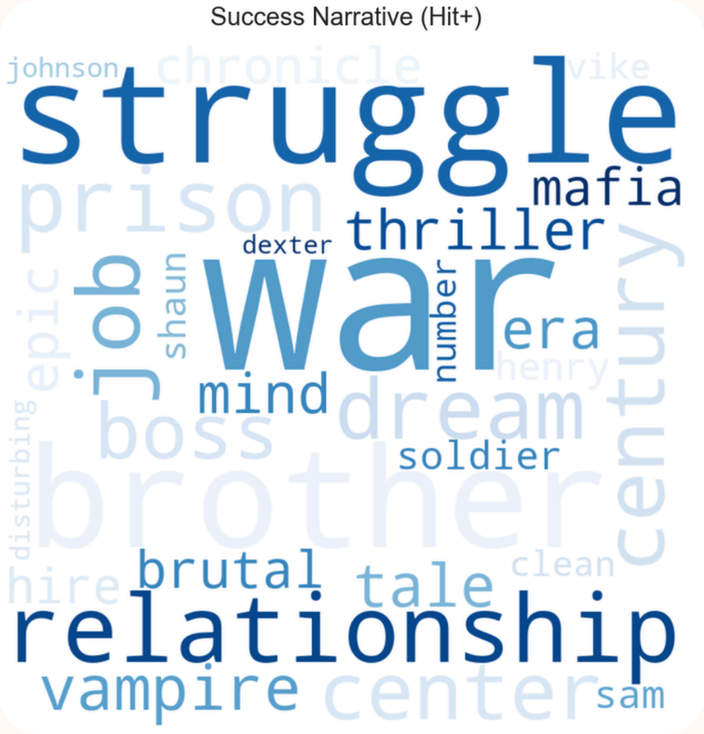

갈등중심 어휘

성장 서사

진중한 사건 서사

- 흥행작은 전쟁 투쟁 등 **갈등 중심**, 인물 간 관계 등 **성장 서사**의 어휘가 두드러짐
- 비흥행작은 마을, 사랑, 비밀 등 **일상적 공간이나 관계**, 사건 중심의 **소프 드라마적** 어휘 주로 등장

05

데이터 분석 줄거리 및 장르 키워드 분석 (흥행)

흥행 영화 BERTopic

- **판타지 어드벤처 및 모험**(7.5%), **SF 및 우주 SF 스릴러**(5.2%), **정통 멜로 및 로맨틱 드라마**(4.8%)가 상위권에 위치
- 판타지 어드벤처 및 모험(7.5%)을 제외하고는 각 **클러스터의 비중 차이는 두드러지지 않았음**

* BERTopic: 임베딩 벡터로 클러스터링해 각 클러스터의 토픽을 추출하는 기법

05

데이터 분석 줄거리 및 장르 키워드 분석 (흥행)

흥행 드라마 BERTopic

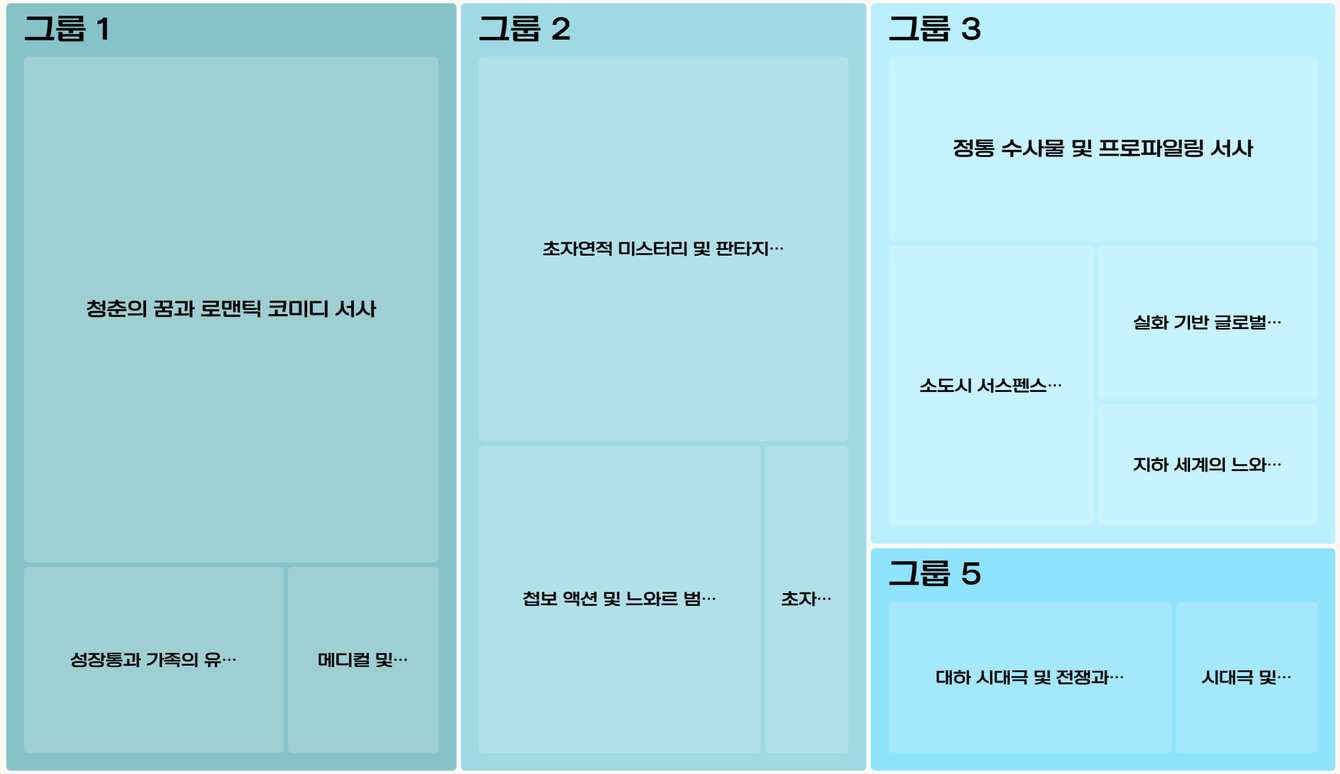

- **청춘의 꿈과 로맨틱 코미디 서사**(18.1%)와 **초자연적 미스터리 및 판타지 서사**(12.5%)가 가장 많음
- **범죄 서사**(7.6%)는 수가 적지만 유사한 클러스터를 합쳐 거대한 군집 형성

05

데이터 분석 줄거리 및 장르 키워드 분석 (비흥행)

비흥행 영화 BERTopic

- 거대한 **클러스터로 통합**되는 특성
- 영화는 거대한 비흥행의 유형을 보여주고 있음
- 완성도 떨어지는 **저예산 스릴러/로맨스/코미디**가 가장 큰 클러스터를 이루고, **저예산 공포 영화**가 그 다음을 이음

05

데이터 분석 줄거리 및 장르 키워드 분석 (비흥행)

비흥행 드라마 BERTopic

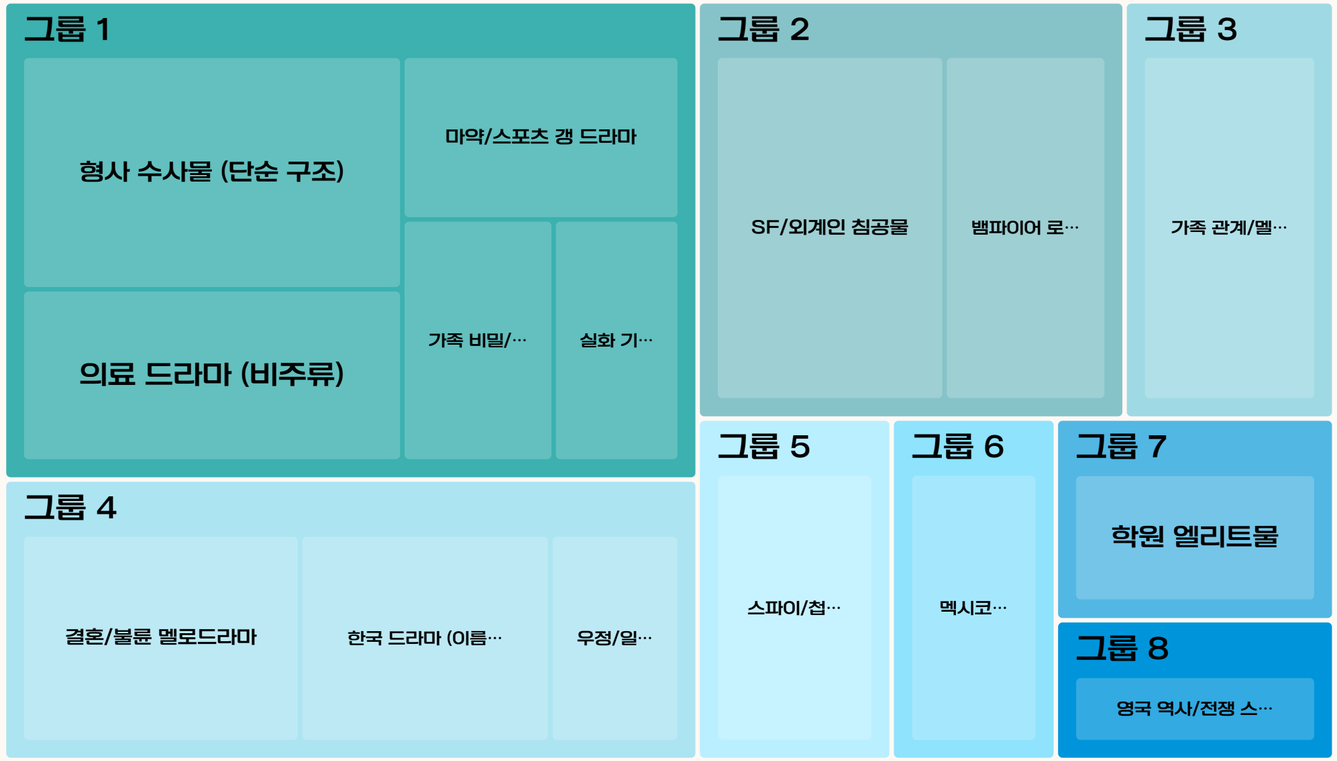

- **수사극**(7.1%)이 가장 많은 비중을 차지
- SF(6.8%)가 그 뒤를 이음
- 비흥행작의 클러스터를 통합했을 때 **서로 유사해 보이지 않는 서사들**이 하나의 클러스터로 통합됨

→ 비흥행작의 서사 구조가 **명확하지 않음**을 암시

05

데이터 분석 리뷰 심층 분석

리뷰 수와 긍정 반응 구조 비교

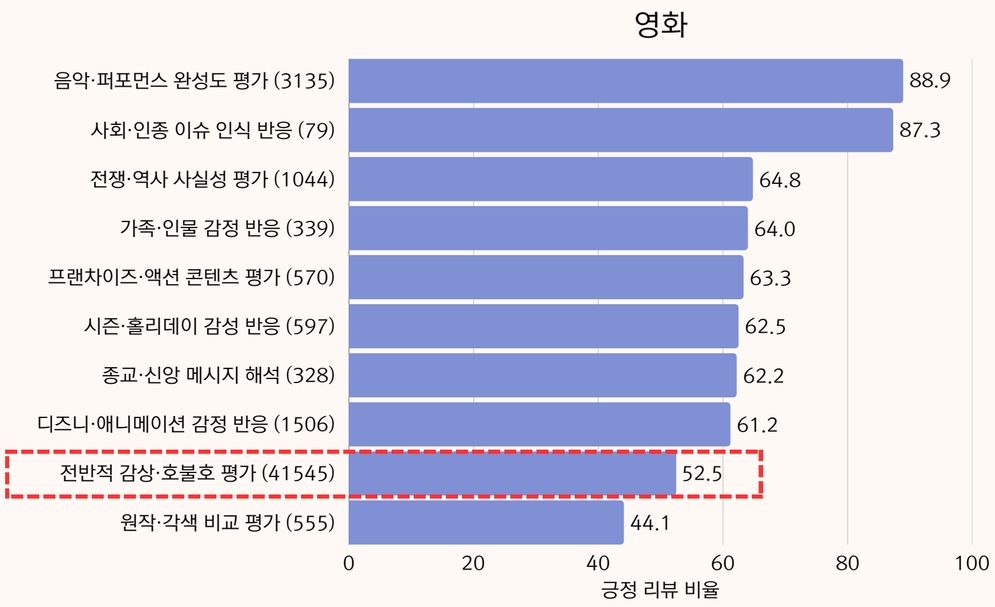

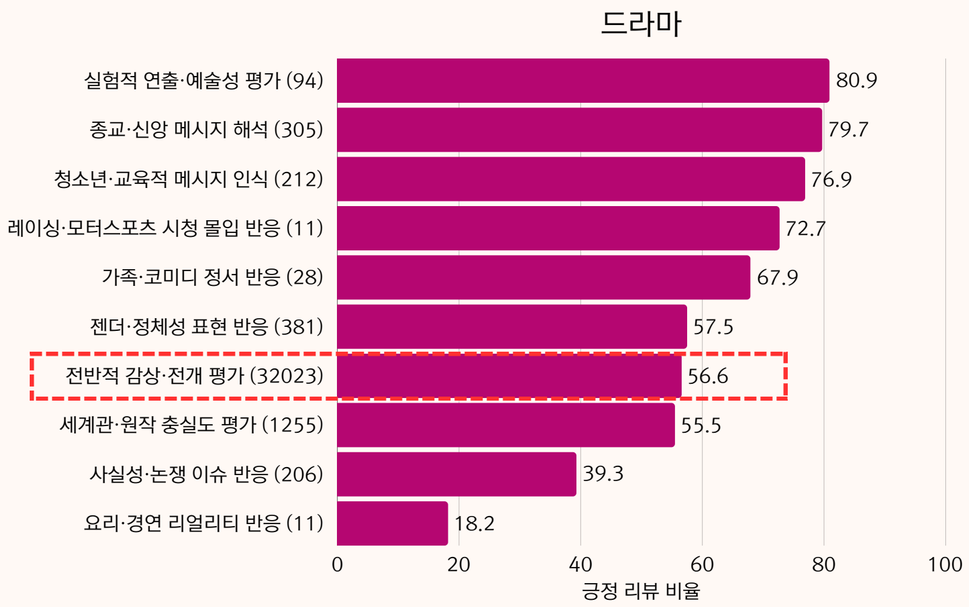

- 영화와 드라마는 리뷰 감정 반응 언어의 초점이 명확히 다름
- 영화 리뷰는 **관람 중 체감 요소**(연출·퍼포먼스)에 대한 긍정 반응이 높음
- 드라마 리뷰는 **사회적 의미와 메시지 해석**에 대한 긍정 반응이 높음
- **전반적 감상** 클러스터에 **가장 많은 리뷰**가 집중됨

05

데이터 분석 리뷰 심층 분석

영화/드라마 전반적 감상 클러스터 분석

긍정 리뷰 키워드

beautiful · fun · enjoyable · funny
perfect · great · original

보는 재미와 몰입 가능한 엔터테인먼트 경험에 대한 평가

VS

부정 리뷰 키워드

boring · slow · terrible · worst
disappointing · waste · bad

전개 속도와 기대 대비 만족도 차이에 반응

- 가장 많은 리뷰가 집중된 '전반적 감상' 클러스터는 **작품에 대한 전체 만족·불만을 직접적**으로 드러냄
- 전반적 감상의 호불호는 **작품의 메시지**보다 관람 중 느껴지는 **재미와 몰입도**에서 형성됨

05

데이터 분석 SUMMARY

장르별 흥행율 분석

- 역사, 정치 등 거대 서사를 기반으로 한 작품에서 흥행 비중이 높음
- 공포나 소프 드라마처럼 구조가 단순, 반복적인 장르는 흥행 비중 낮음

줄거리 및 장르 키워드 분석

- 흥행 영화는 판타지 어드벤처와 SF 계열이 상위 비중을 차지
- 비흥행 영화는 코미디, 액션, 공포 장르로 클러스터링
- 흥행 드라마는 로맨스 코미디, 스릴러 장르가 상위 비중
- 비흥행 드라마는 서사 구조가 명확하지 않음
- 드라마는 영화보다 클러스터 종류가 적음

줄거리 키워드 분석

- 전쟁이나 정치 등 진중한 요소에 관련된 어휘가 흥행작에서 자주 등장
- 사랑이나 친구 등 관계에 관한 어휘가 비흥행작에서 자주 등장
- 사건보다 관계 중심 작품들의 비흥행
- 흥행/비흥행 장르적 특징이 어휘 차이에 등장
- 특히 비흥행 작품들의 장르적 특성이 반영

리뷰 심층 분석

- 영화는 음악·퍼포먼스 등 체감 완성도 중심으로 평가됨
- 드라마는 메시지와 연출 의도 등 의미 해석 중심으로 평가가 나뉨
- 대중적 호불호는 메시지보다 보는 재미와 관람 몰입도에서 결정됨

06

머신러닝 흥행 예측 모델링 - 피처 선택

타겟 변수

흥행 이진 변수

- 흥행을 상위 20%, 비흥행을 하위 40%로 라벨링 (중간층은 제거)

종속 변수

임베딩 데이터

- 장르 및 줄거리를 QWEN-3 모델을 통해 임베딩하여 정량화 (1024차원)

인코딩 데이터

- 장르: 멀티 라벨 인코딩
- 언어/국가 : 원핫 인코딩

기타 메타데이터

- 개봉월(영화), 방영월(드라마): 월 변환 → 순환 인코딩

06

머신러닝 흥행 예측 모델링 - 학습

이진 분류

- 콘텐츠 흥행 여부를 확률(0~1)로 예측하는 이진 분류 문제로 설정

클래스 불균형 완화

- 영화·드라마 데이터에서 흥행 작품이 소수 클래스(약 1:2 비율)
- 흥행 클래스에 가중치를 적용해 불균형 문제를 완화하며 학습

모델 다양화

- 트리 기반 모델(LightGBM, XGBoost): 예측 안정성 확보, 피처 중요도 해석의 일관성을 검증
- 신경망 모델(MLP): 비선형 패턴 학습, 임베딩 활용 효과 분석
- 앙상블 모델: Soft Voting으로 균형 잡힌 예측 모델 구성

튜닝을 통한 모델 성능 개선

- 흥행 작품을 놓치지 않는 것이 중요해 Precision과 Recall의 균형을 고려한 F1 기준 사용
- 임계값 조정 및 하이퍼파라미터 튜닝으로 모델 성능 추가 개선

* Soft Voting 앙상블: 여러 모델의 예측 확률을 평균해 안정적인 최종 예측을 수행하는 방식

06

머신러닝 흥행 예측 모델링 - 성능 비교

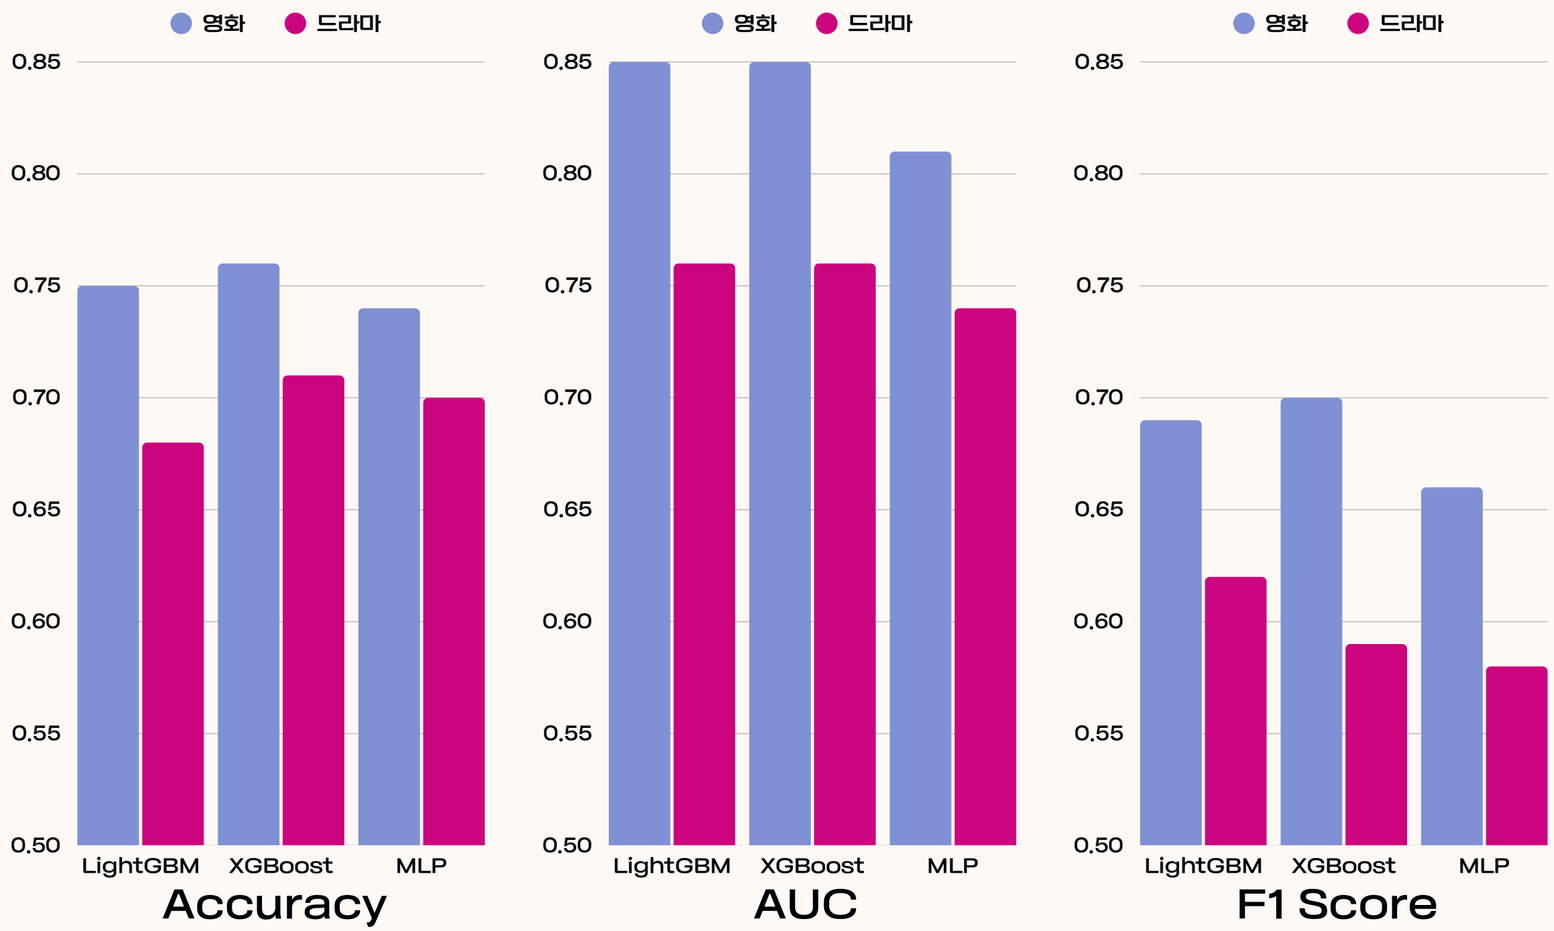

영화

- XGBoost가 전체적으로 우수
- LightGBM는 AUC 기준 동급 상위권

드라마

- 정확도는 XGBoost가, F1 기준 실질 성능은 LightGBM이 우수
- 트리 기반 모델(LightGBM, XGBoost)은 임베딩 기반 흥행 예측에서 안정적인 성능을 보였음
  → 단순히 정확도만 높이기보다, 흥행 가능작을 놓치지 않도록 설계

06

머신러닝 흥행 예측 모델링 - SHAP value 결과

영화

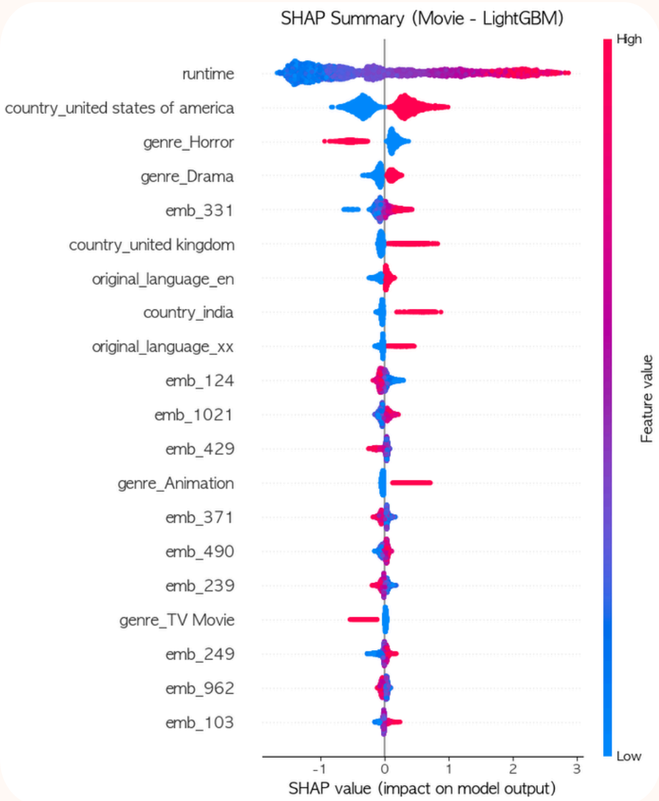

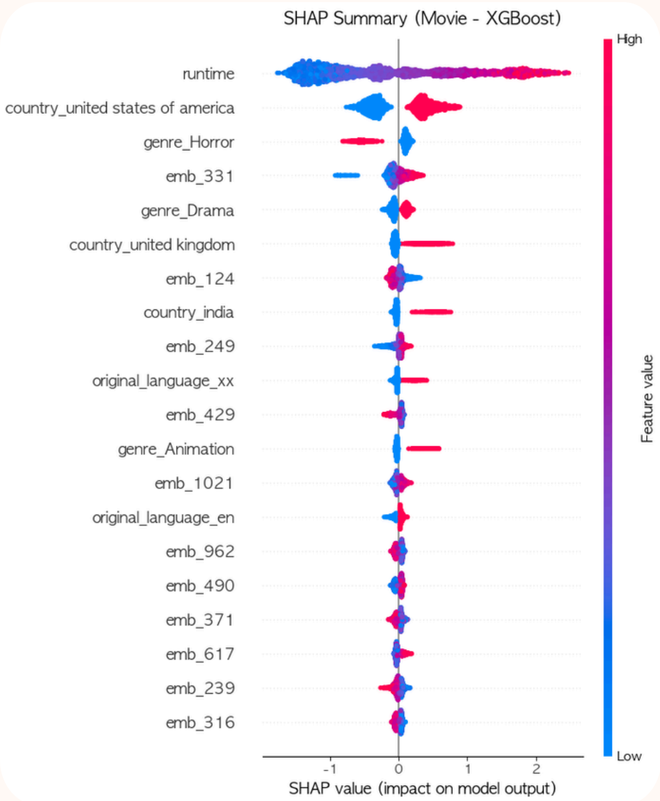

- 영화에서는 **러닝타임이 길수록 흥행**, 호러 장르일수록 비흥행 쪽으로 작용하고, 제작 국가(미국)도 중요한 신호로 쓰임
- 상영 시간과 장르, 제작 국가뿐 아니라, **서사도 중요한 흥행 지표**임을 시사
- 모델 간 SHAP value가 일관적으로 작용

06

머신러닝 흥행 예측 모델링 - SHAP value 결과

드라마

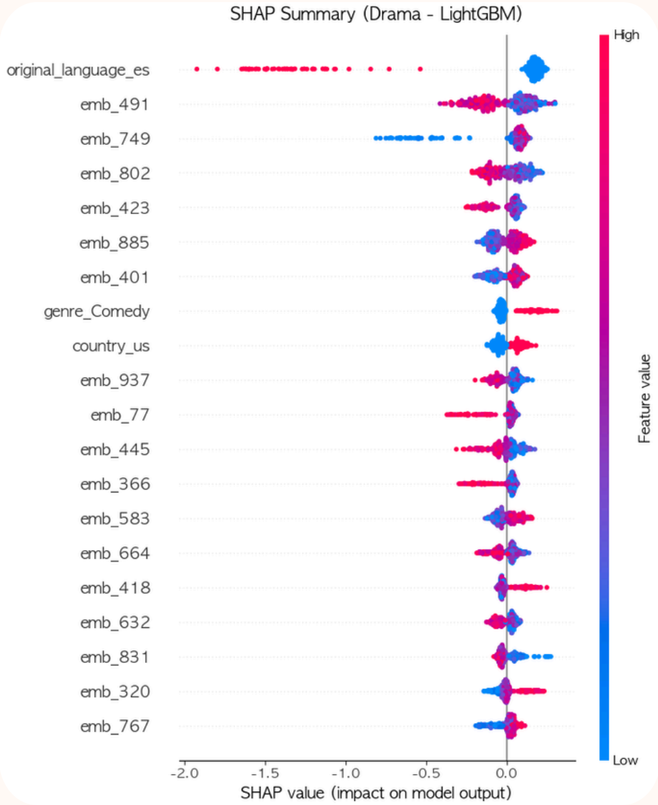

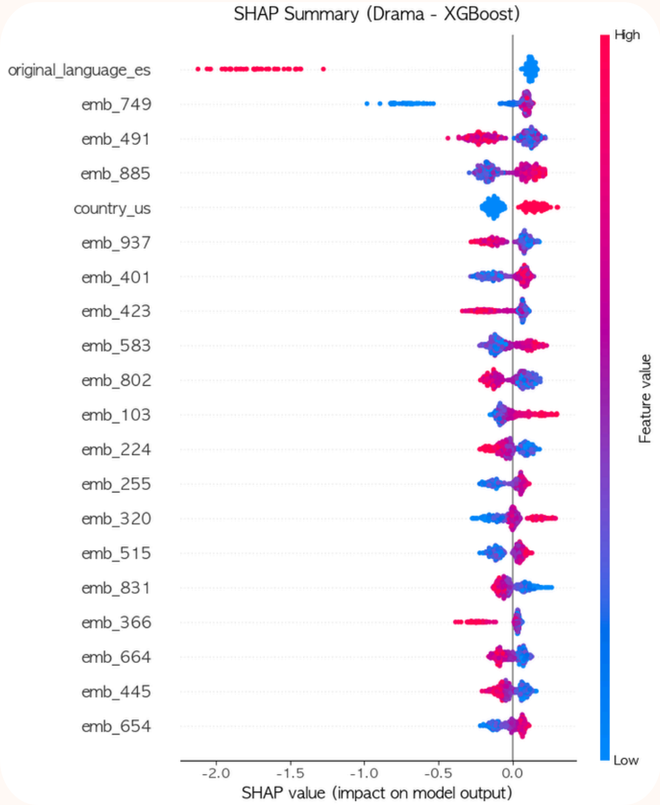

- 스페인어가 비흥행의 요소
  → 텔레노벨라 장르의 신호
- 코미디 장르가 흥행의 요소
- **서사도 중요한 흥행 지표**임을 확인
- SHAP value가 일관적으로 작용

* 텔레노벨라(Telenovela): 사랑·가족·갈등을 중심으로 전개되는 중남미권 연속 드라마 장르

06

머신러닝 흥행 예측 모델링 - 앙상블 모델 구축

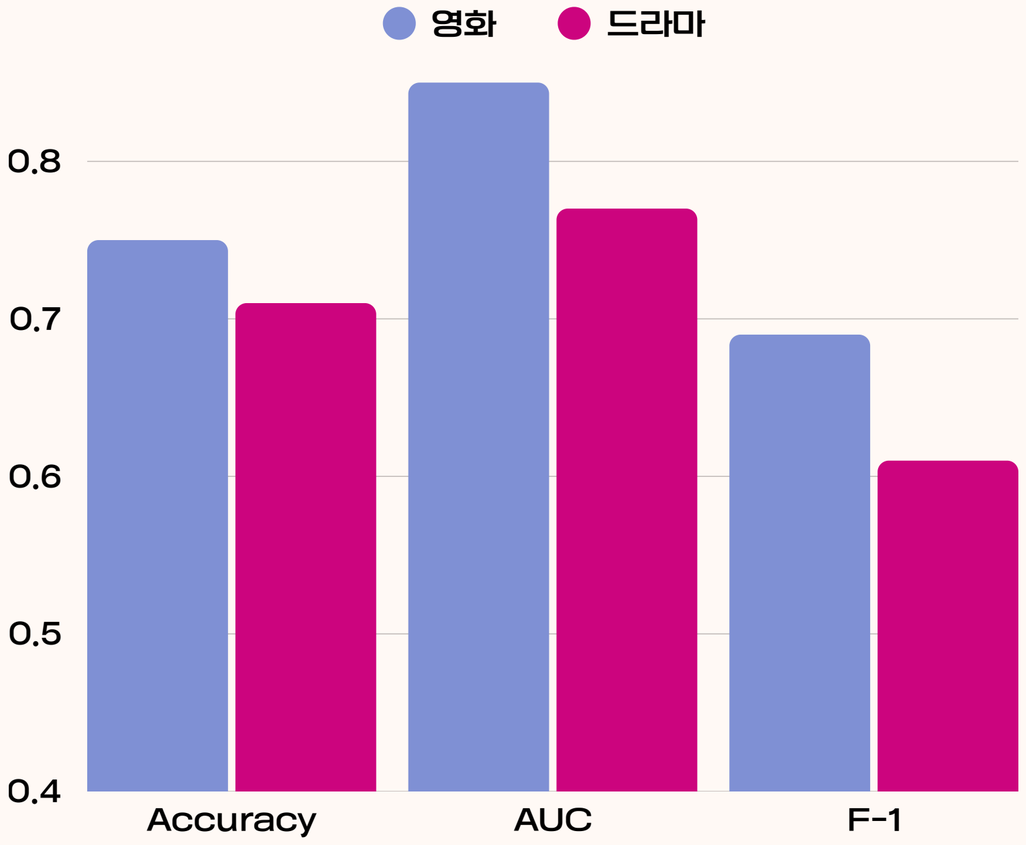

모델 성능 개선용 Soft Voting 모델

- **영화 앙상블**은 AUC 0.85, F1 0.69, Accuracy 0.75로 단일 모델과 비슷한 AUC를 유지하면서 **F1을 소폭 끌어올림**
- **드라마 앙상블**은 AUC 0.77, F1 0.61, Accuracy 0.71로, 단일 모델 대비 **약간의 성능 향상**과 보다 **안정적인 예측**을 보여줌
- **영화**에서는 흥행 기준이 되는 임계값을 낮춰(Threshold: 0.27) **흥행 후보를 더 넓게** 잡았고, **드라마**에서는 영화보다 **다소 엄격한 기준** (Threshold: 0.33)으로 흥행/비흥행 분류
- **Soft Voting 앙상블**이 각 모델의 장점을 합쳐 극단적인 오판을 줄이고 **균형 잡힌 성능**을 내는 방향으로 작동

06

머신러닝 흥행 예측 모델링 - 요약

영화

러닝타임은 일정 시간 이상 확보할수록, 제작 국가는 미국일수록 흥행에 유리하며, 호러 장르는 비흥행 경향을 보임

드라마

제작 언어가 스페인어인 경우 비흥행 경향을 보였고,
장르가 코미디일수록 흥행 확률이 높아지는 경향이 나타남

공통

영화와 드라마 모두에서 서사 구조와 장르 특성이 흥행 확률에 유의한 영향을 미치는 것으로 나타남

07

결론

인사이트

콘텐츠 흥행은 우연 아닌 서사 구조로 설명·예측 가능	영화와 드라마는 서로 다른 흥행 논리를 가짐	흥행작은 갈등의 축적과 인물 변화를 명확히 보임	비흥행의 원인은 서사 부재가 아닌 구조적 모호성	서사 분석은 흥행 판단의 정량적 도구가 될 수 있음

비즈니스 솔루션

- 제작·구매·투자 전 단계에 시놉시스만으로 흥행 가능성 예측
- 의사결정 리스크를 사전에 최소화하는 데이터 기반 기준 제공

향후 계획

- 텍스트 분석에 포스터·트레일러·배우 네트워크를 결합한 멀티모달 확장
- 모델의 설명력과 흥행 예측 성능을 추가로 강화

07

결론

영화/드라마 흥행 공식

영화

- 명확한 장르, 역사, 정치 등 거대 서사
- 서사의 밀도를 반영하는 러닝타임 확보
- 미장센/조명/음악 등 영상 제작 퀄리티 보장
- 일상코미디, 좀비 아포칼립스 등 클리셰적이고 반복적인 영화는 지양

드라마

- 명확한 장르
- 진중한 토픽 중심의 서사
- 가족 복수극, 멜로 등 감정 중심은 지양
- 완성도 있는 코미디 장르 공략
- 체감 경험 극대화 전략

07

결론

분석의 한계점

- 드라마 데이터의 부족해 영화 대비 변동성이 다소 크게 나타날 수 있다는 한계
- 줄거리 길이가 짧은 작품이 많아 흥행 예측하기에 충분한 정보가 임베딩에 반영되지 못했을 가능성
- 배우나 캐스팅 파워 요소를 결합한다면 흥행 예측의 설명력과 현실성이 더욱 강화될 것으로 기대

→ 본 분석 결과는 흥행 가능성에 대한 보조적 의사결정 도구로 활용하는 것이 적절

08

대시보드 제작

개요

Streamlit 기반 인터랙티브 분석 시스템 제작

대상

OTT 콘텐츠 기획·제작·투자 의사결정자

구성

Page 1 흥행 트렌드 파악

- 목적: “지금 어떤 콘텐츠가, 왜, 얼마나 잘 되고 있는가?” 확인
- 내용: 핵심 흥행 지표, 연도별 흥행 트렌드, OTT별 흥행작 점유율, 상위 흥행 콘텐츠 Top 5

Page 2 흥행 요인 분석

- 목적: “어떤 특성이 흥행/비흥행을 만드는가?” 파악
- 내용: 흥행작/비흥행작의 키워드 분석(TF-IDF, BerTopic 결과), 흥행작 영화 클러스터 Map 등

Page 3 흥행 예측

- 목적: “그래서, 무엇을 만들어야 하는가?” 제시
- 내용: 가상 제작 시나리오 흥행 시뮬레이션, 임베딩 기반 유사 콘텐츠 추천

상세 페이지

앱 배포 링크 바로가기 (클릭)

감사합니다

THANK YOU