# 글로벌 흥행 콘텐츠의 공식:

## TMDB-IMDb 영화·드라마 데이터 분석 프로젝트

**6조_육개장 4인분**

김승윤 tmddbs6258@gmail.com
김인표 inpyo104@gmail.com
윤예원 yywon2@gmail.com
차지연 snsqlc486@gmail.com

2025. 12. 30.

# 목차


01 프로젝트 개요

02 데이터 확보

03 성과 지표 산출

04 EDA

05 데이터 분석

06 머신러닝

07 결론

08 대시보드 제작

01

# 프로젝트 개요 배경 및 문제 정의

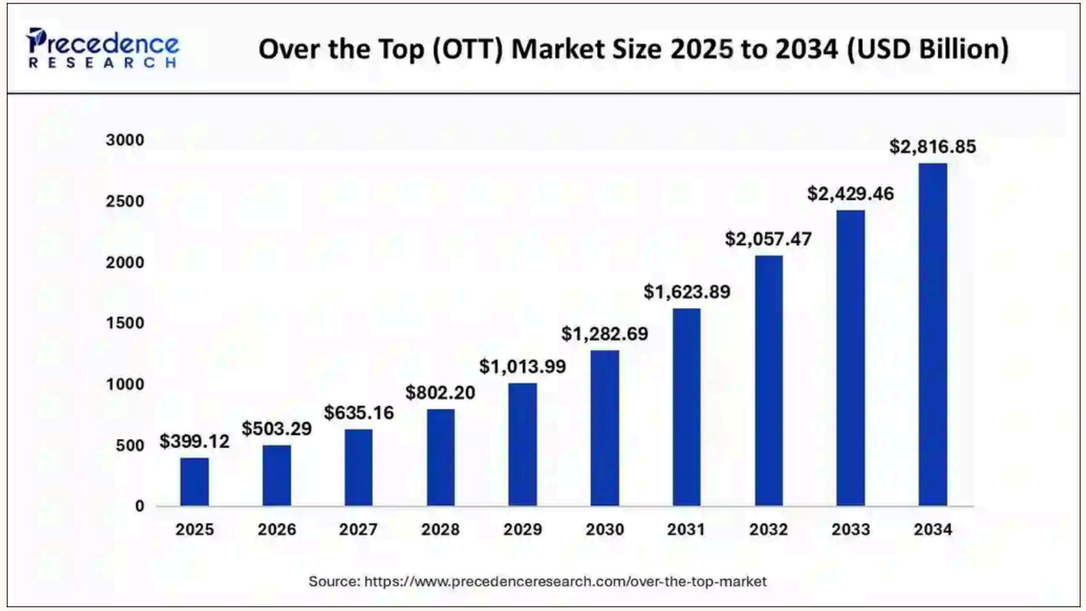


- 현재 글로벌 OTT 시장은 넷플릭스·아마존 중심으로 약 4천 억 달러, 2034년 2.8조 달러로 **고성장 전망**
- 시장은 확대되었으나, 성숙 시장에서 **가입자 증가 둔화·해지율 상승**
- 이에 따라 구독 수익성 확보를 위한 **경쟁 심화**

→ **흥행 가능성 높은 콘텐츠 선별·기획 역량**이 OTT 핵심 경쟁력

* OTT(Over-The-Top): 기존 케이블 TV나 셋톱박스 같은 전통 방송망을 거치지 않고 인터넷을 통해 영화, 드라마, 방송 등 미디어 콘텐츠를 직접 제공하는 서비스

01

# 프로젝트 개요 주제 및 목표

**프로젝트 목적** | 글로벌 영화·드라마 콘텐츠의 흥행 패턴과 핵심 특성을 데이터로 분석해, OTT 관계자에게 콘텐츠 제작과 투자 판단 기준을 제공

**프로젝트 주제** | 글로벌 영화·드라마의 흥행작 특성을 파악하고, 흥행 기준을 제시하여, 흥행 예측 모델 개발

**프로젝트 기간** | 2025.11.24. - 2025.12.28.

**프로젝트 결과물**

흥행점수 및 흥행 콘텐츠 예측 모델
인사이트 및 비즈니스 솔루션
Streamlit 기반 인터랙티브 분석 시스템

01

# 프로젝트 개요 분석 내용

**흥행 키워드**

흥행 콘텐츠 특징을
흥행 콘텐츠의 어휘
특징으로 구체화

**흥행 서사 도출**

서사 토픽 모델링을
통해 흥행 콘텐츠의
서사적 특징을 파악

**리뷰 범주화**

리뷰 범주화로
사용자의 반응을
이끌어낸 콘텐츠의
요소 구체화

**흥행 예측 모델**

트리 기반 모델과
신경망 모델을 통해
흥행을 미리 예측할
수 있는 모델 개발

02

# 데이터 확보 데이터 수집

## TMDb API

TMDb에서 제공하는 공식 API를 통해 수집

다양한 영화/드라마 메타 데이터 제공

사용자의 기여를 통해 데이터가 기입되므로 일부 정보가 구체적이지 않음

리뷰 데이터 부족

## IMDb 크롤링

IMDb 사이트에서 크롤링

방대한 영화/드라마 메타 데이터와 리뷰 데이터 제공

공식 API가 없어 수집에 어려움

평점 작성기준이 까다로워 구체적인 리뷰 수집 가능

02

# 데이터 확보 데이터 전처리

| 1 | 2 | 3 | 4 |
|---|---|---|---|
| 필요 컬럼 선정 | 카테고리 통합 | 다중 속성 분리 및 정규화 | 최종 데이터셋 |
| 결측값 대체 불가능 OR 불필요한 컬럼 삭제 | 범주 수가 과도한 카테고리 정제 및 통합 | 다중속성 컬럼 분리 및 테이블 정규화 | 최종 데이터셋 구성 및 분석 시작 |

02

# 데이터 확보 최종 데이터셋

| 구분 | 영화 데이터 | 드라마 데이터 |
|---|---|---|
| 데이터 기간 | 2005년 1월 1일 ~ 2025년 11월 30일 (약 21년 간) | |
| 데이터 규모 | 약 26,000편 | 약 3,000편 |
| 성과 데이터 | 평점 수, 평점 | |
| 서사 데이터 | 줄거리, 장르 | |
| 리뷰 데이터 | IMDb 리뷰 텍스트<br>* IMDb ID를 식별자로 TMDB 데이터와 결합 | |
| 플랫폼 데이터 | OTT 구독 플랫폼 정보 | |
| 수익·비용 데이터 | 제작비 / 수익 정보 (일부) | 없음 |
| 기타 메타데이터 | 개봉일, 러닝타임, 제작 언어/국가 등 | 방영 시작일, 시즌 정보, 제작 언어/국가 등 |

03

# 성과 지표 산출 흥행점수 계산

질적 지표 양적 지표

## ( 50% + 50% ) × 100%

### 리뷰 감성 점수

시청자의 리뷰에서 드러나는
정성적 평가의
리뷰 평가 중심 가중 평균

### 평점

시청자가 자신의 시청 후기를
10점 만점의 정량적 척도에
표기한 점수

### 평점 개수

관객 정보를 대신해 정량적
흥행 지표를 로그값으로 사용

03

# 성과 지표 산출

흥행점수 분포

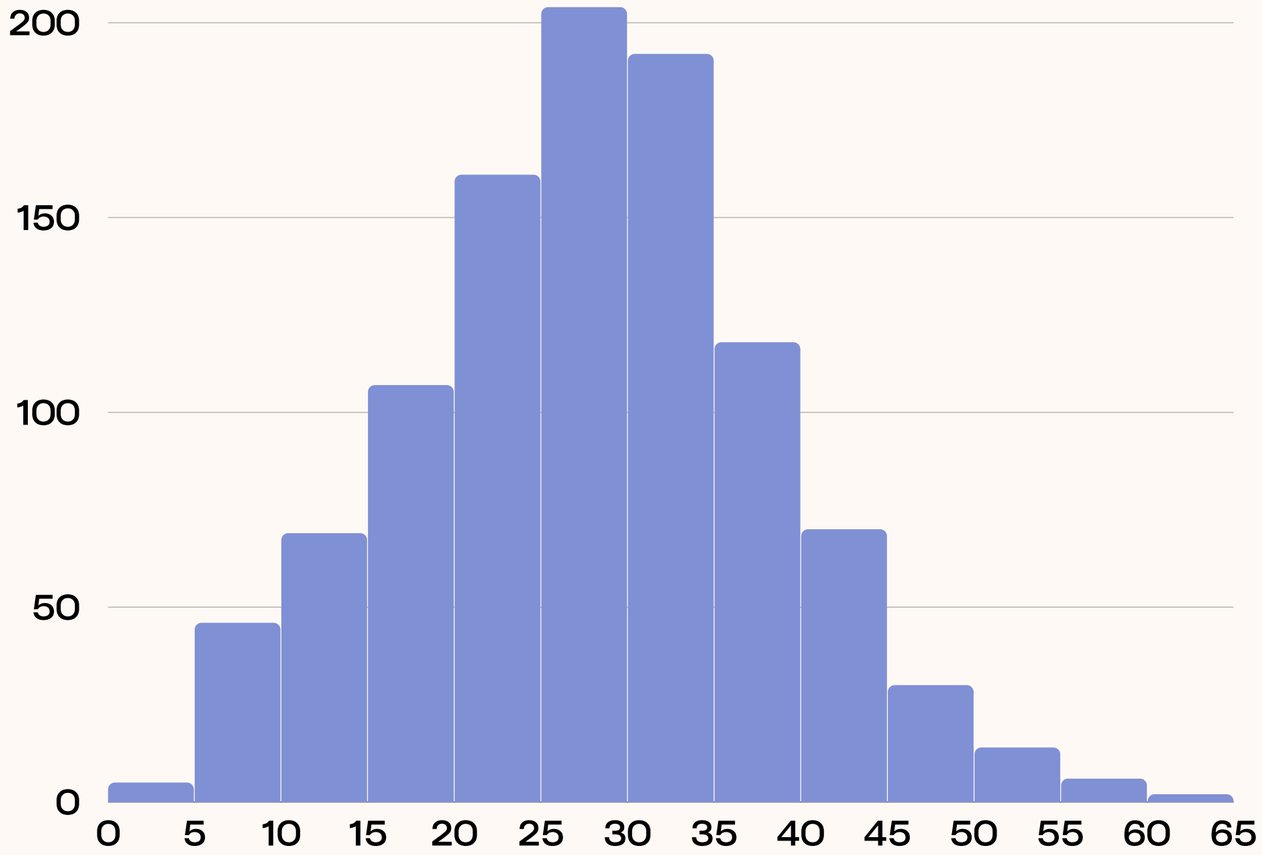


## 흥행작 : 상위 20%

## 비흥행작 : 하위 40%

- 최종 그래프는 정규 분포에 가깝지만 비틀린 모양
- **흥행작**은 파레토 법칙에 따라 **상위 20%** 라고 가정
- **비흥행작**은 데이터 삭제 최소화 및 예측 모델 성능 향상을 위해 **하위 40%**로 정의

* 파레토 법칙: 전체 시장의 상위 20%가 나머지 80%를 차지한다는 원리

04

# EDA 국가별 흥행 비중

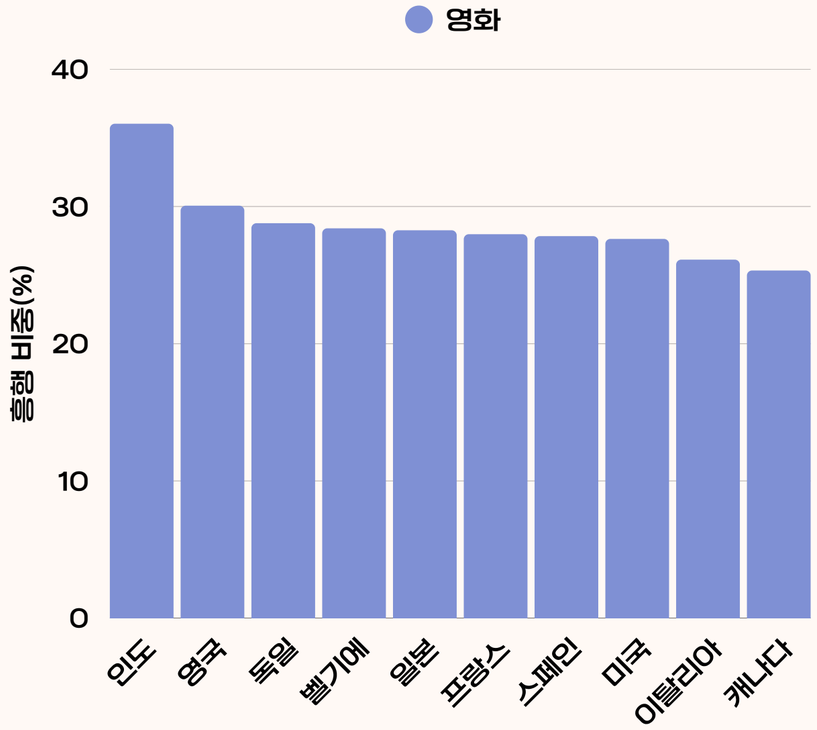


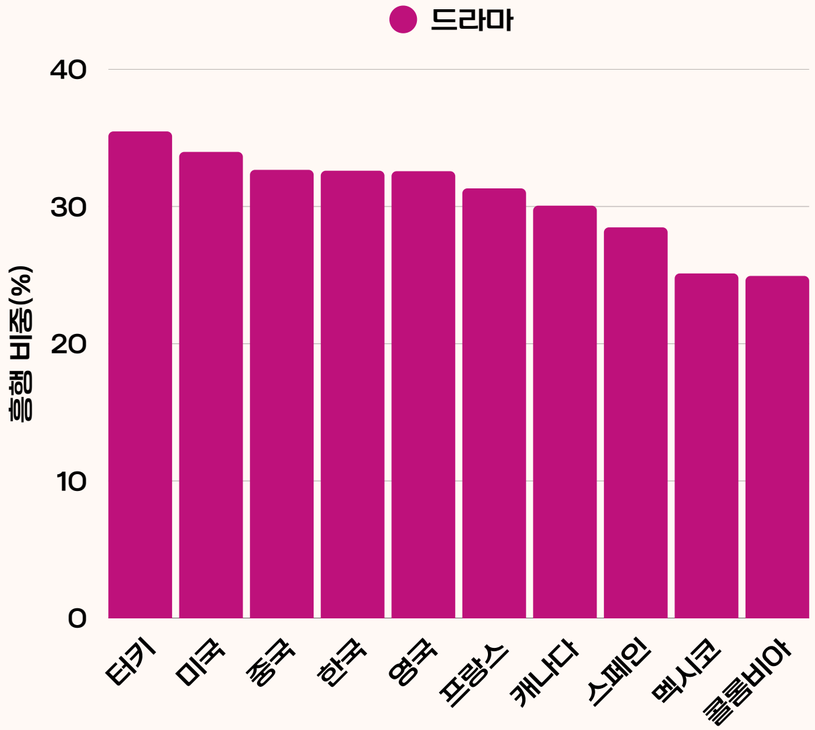


- **국가별 흥행점수가 유사**하나 인도가 높게 나온 편
- 인도 영화가 해외 수출되는 경우 등록됐을 수 있음

- 미국을 제외하고 **아시아권이 상위권**에 위치
- 유럽 및 아메리카 지역은 비교적 하위에 위치

04

# EDA OTT별 흥행 비중

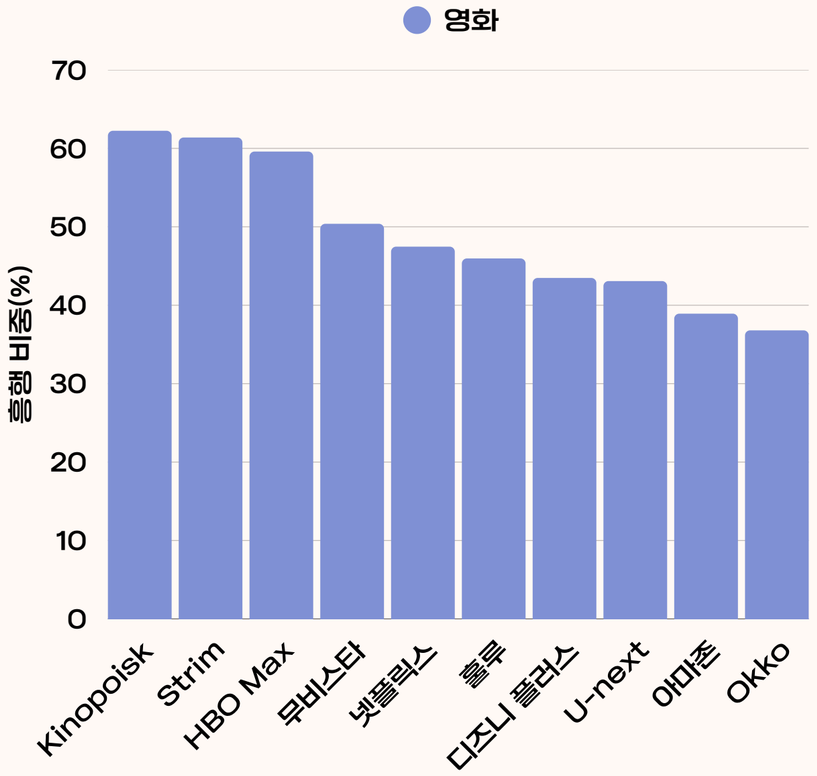


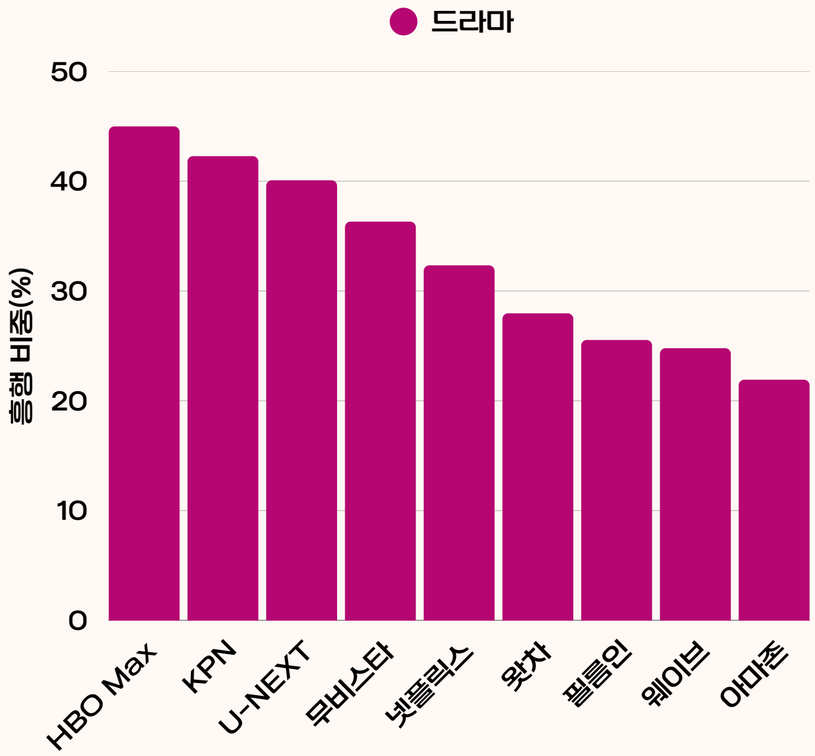


- **거대 OTT 기업의 흥행작 비율은 낮은 편** → 여러 영화/드라마를 동시에 가지고 있기 때문일 것으로 예상
- **소규모 OTT는 흥행작 위주 확보 전략**을 취하는 것으로 보임

05

# 데이터 분석 장르별 흥행 비율

## 영화

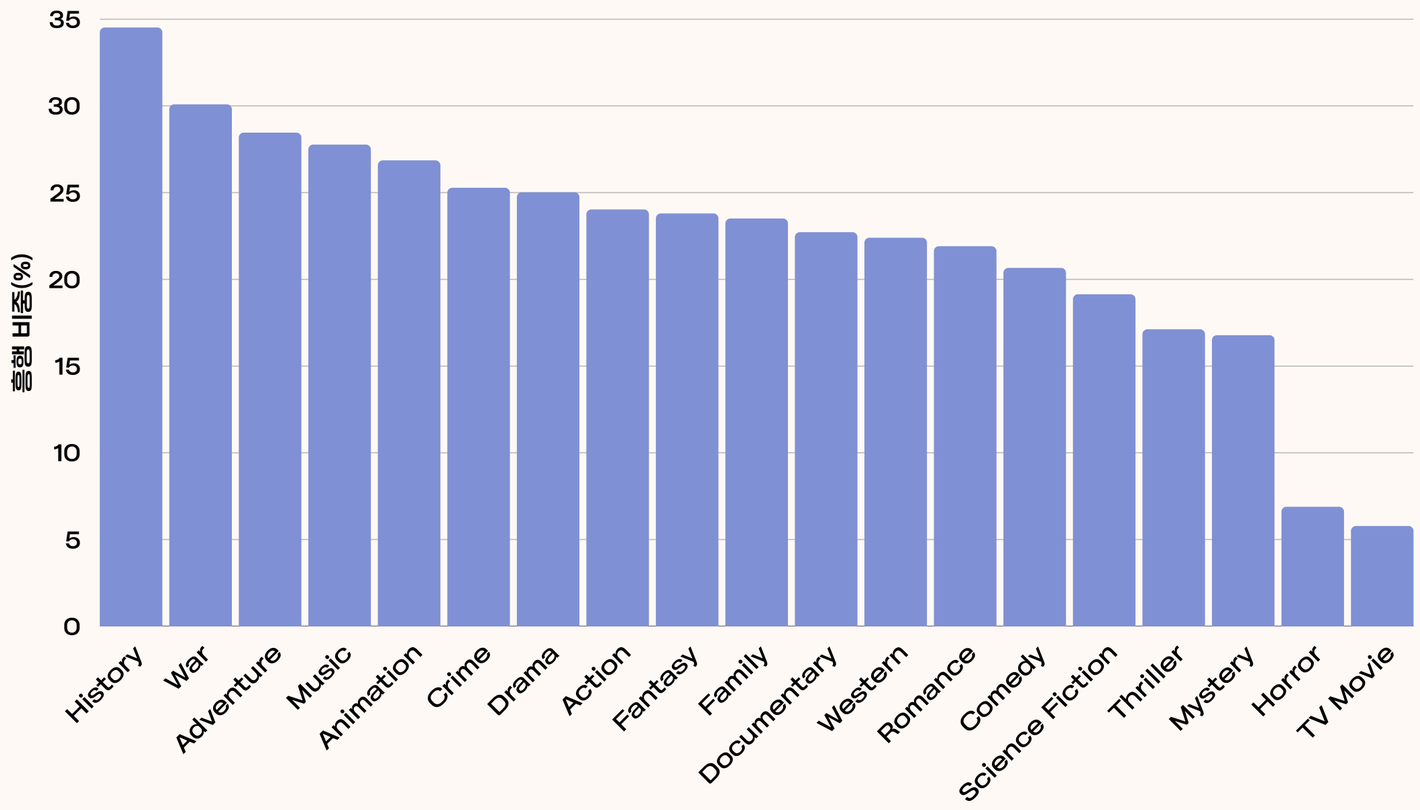


**카이제곱 검정 결과**

P-value : 0.00***
Cramér's V: 0.1459
**통계적으로 유의**

- 장르에 따른 흥행 비율 차이는 **유의미**
- 역사, 전쟁 등 거대 **서사 관련** 장르에서 **흥행율 ↑**
- **공포, TV Movie 장르**에서 **흥행율 ↓**

* 카이제곱 검정: 각 범주의 영향이 서로 독립인지 검정하는 통계적 방법

05

# 데이터 분석 장르별 흥행 비율

## 드라마

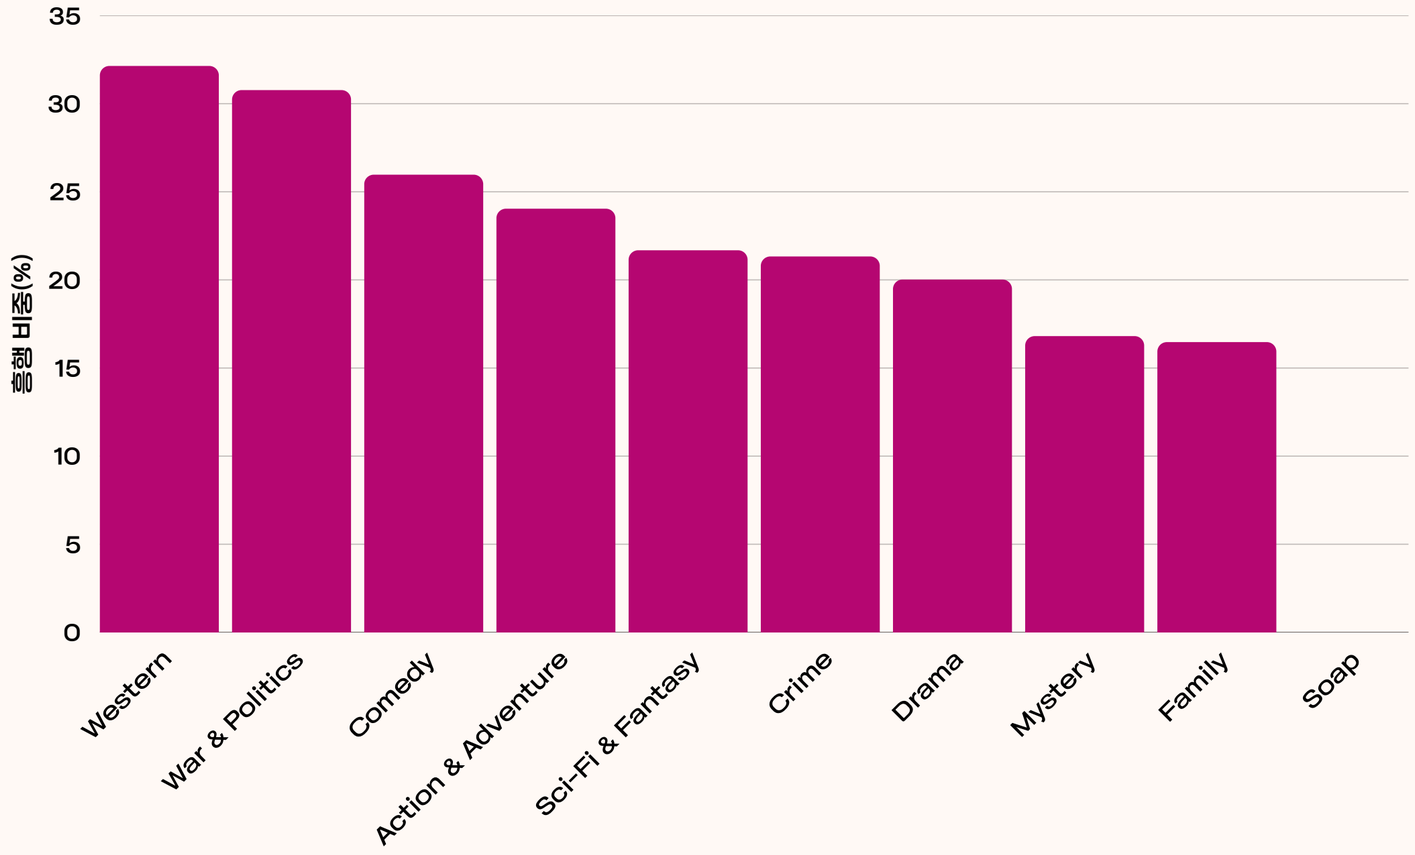


**카이제곱 검정 결과**

P-value : 0.00***
Cramér's V: 0.1813
**통계적으로 유의**

- 장르에 따른 흥행 비율 차이는 **유의미**
- 소프 드라마처럼 **일상 반복 구조**의 장르가 거의 흥행하지 않는 것이 특징

* 소프 드라마(Soap Opera): 아침 드라마나 일일 드라마와 형식·특징이 매우 유사한 해외 연속극 장르

05

# 데이터 분석 줄거리 키워드 분석

## 흥행 vs 비흥행 영화 델타 TF-IDF

### 갈등과 변화 중심 어휘

### 진중한 서사 중심

- 흥행작은 **갈등과 변화 중심** 어휘가 자주 등장
- 전쟁 등 **진중한 서사**나 액션 서사가 많음
- 비흥행작은 **공간이나 관계 중심 어휘**가 많음

* 델타 TF-IDF: 긍부정의 TF-IDF의 차를 구하여 양 집단의 대표 키워드를 확인하는 방법

05

# 데이터 분석 줄거리 키워드 분석

## 흥행 vs 비흥행 드라마 델타 TF-IDF

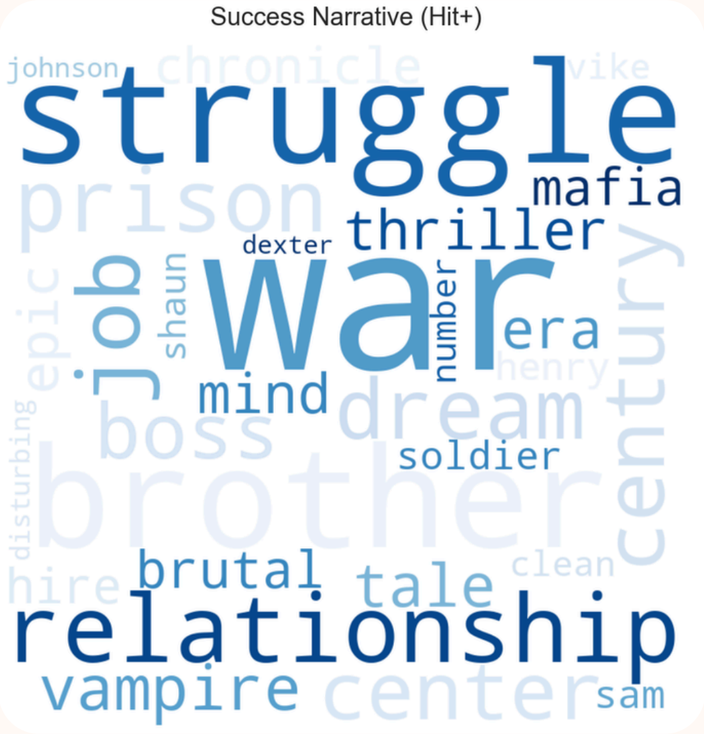

**갈등중심 어휘**

**성장 서사**

**진중한 사건 서사**

- 흥행작은 전쟁 투쟁 등 **갈등 중심**, 인물 간 관계 등 **성장 서사**의 어휘가 두드러짐
- 비흥행작은 마을, 사랑, 비밀 등 **일상적 공간이나 관계**, 사건 중심의 **소프 드라마적** 어휘 주로 등장

05

# 데이터 분석 줄거리 및 장르 키워드 분석 (흥행)

## 흥행 영화 BERTopic

- **판타지 어드벤처 및 모험**(7.5%), **SF 및 우주 SF 스릴러**(5.2%), **정통 멜로 및 로맨틱 드라마**(4.8%)가 상위권에 위치
- 판타지 어드벤처 및 모험(7.5%)을 제외하고는 각 **클러스터의 비중 차이는 두드러지지 않았음**

* BERTopic: 임베딩 벡터로 클러스터링해 각 클러스터의 토픽을 추출하는 기법

05

# 데이터 분석 줄거리 및 장르 키워드 분석 (흥행)

## 흥행 드라마 BERTopic

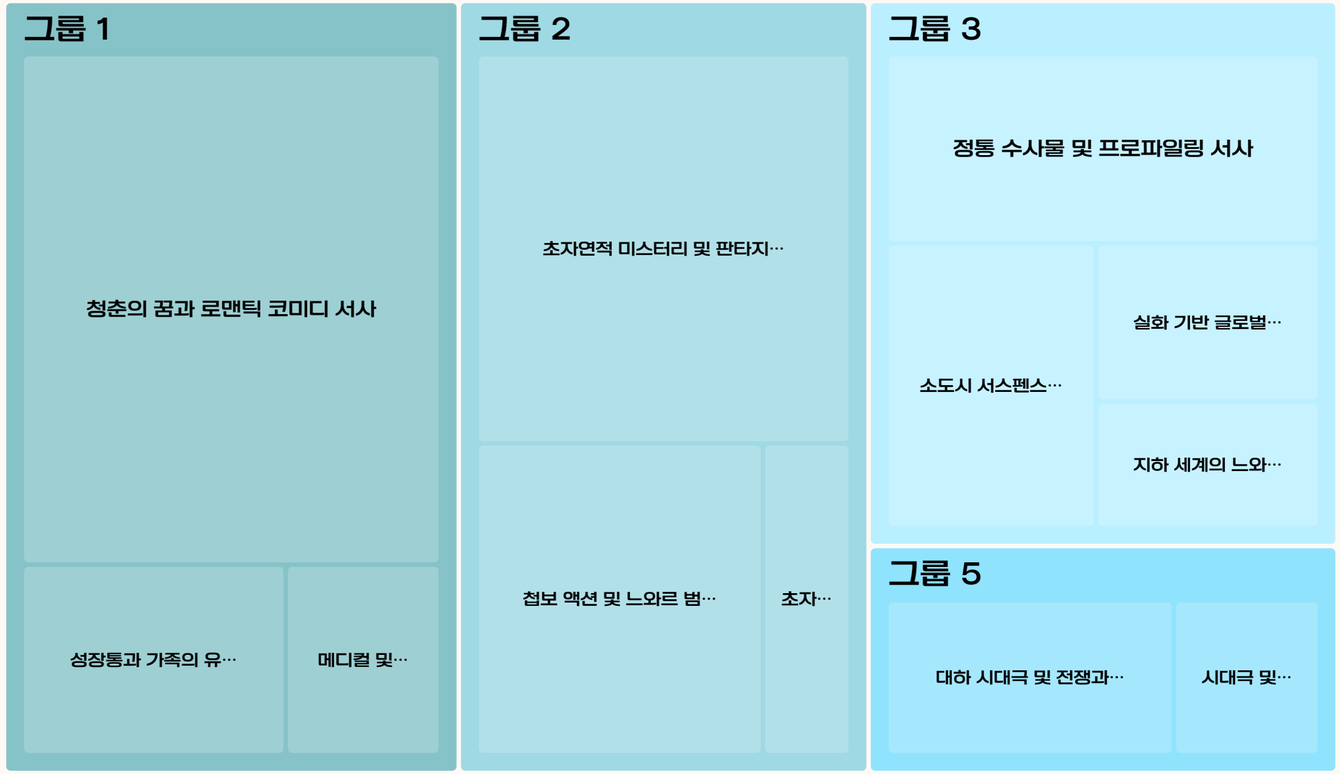


- **청춘의 꿈과 로맨틱 코미디 서사**(18.1%)와 **초자연적 미스터리 및 판타지 서사**(12.5%)가 가장 많음
- **범죄 서사**(7.6%)는 수가 적지만 유사한 클러스터를 합쳐 거대한 군집 형성

05

# 데이터 분석 줄거리 및 장르 키워드 분석 (비흥행)

## 비흥행 영화 BERTopic

- 거대한 **클러스터로 통합**되는 특성
- 영화는 거대한 비흥행의 유형을 보여주고 있음
- 완성도 떨어지는 **저예산 스릴러/로맨스/코미디**가 가장 큰 클러스터를 이루고, **저예산 공포 영화**가 그 다음을 이음

05

# 데이터 분석 줄거리 및 장르 키워드 분석 (비흥행)

## 비흥행 드라마 BERTopic

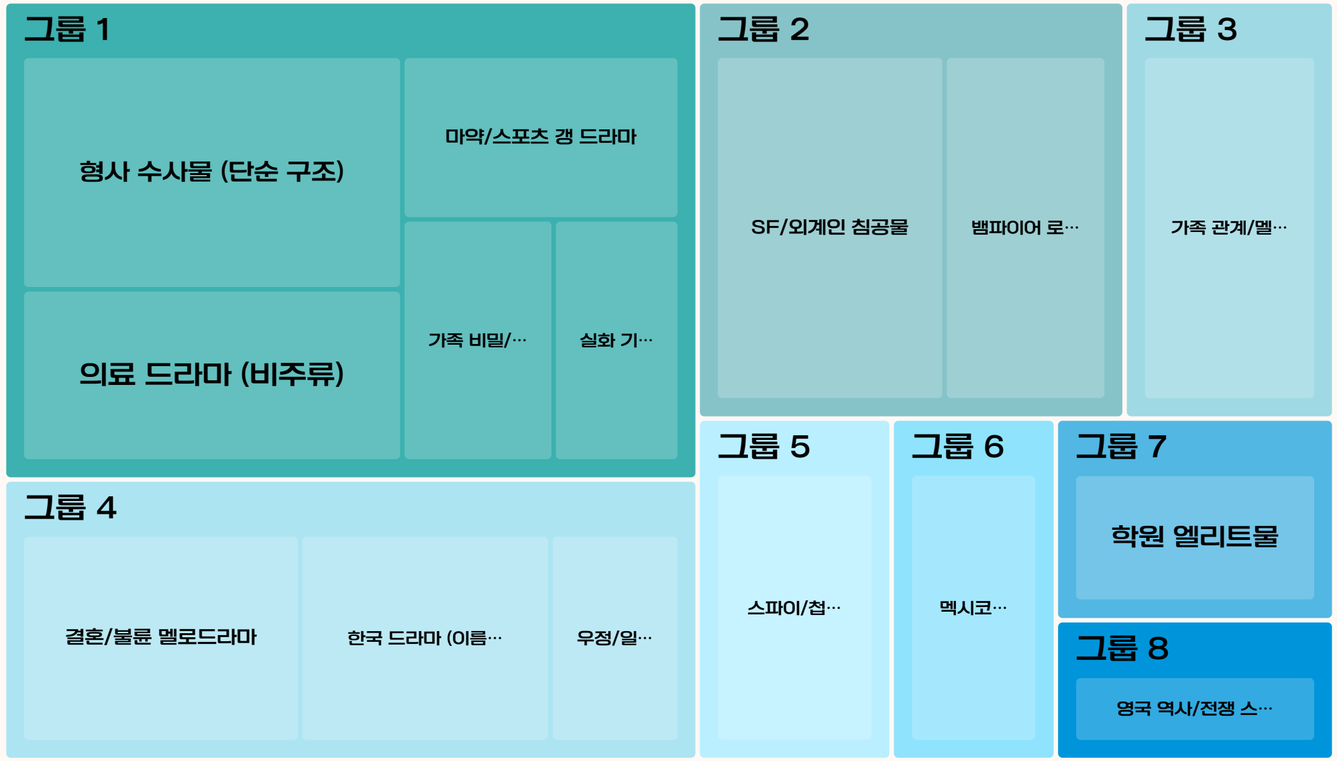


- **수사극**(7.1%)이 가장 많은 비중을 차지
- SF(6.8%)가 그 뒤를 이음
- 비흥행작의 클러스터를 통합했을 때 **서로 유사해 보이지 않는 서사들**이 하나의 클러스터로 통합됨

→ 비흥행작의 서사 구조가 **명확하지 않음**을 암시

05

# 데이터 분석 리뷰 심층 분석

## 리뷰 수와 긍정 반응 구조 비교

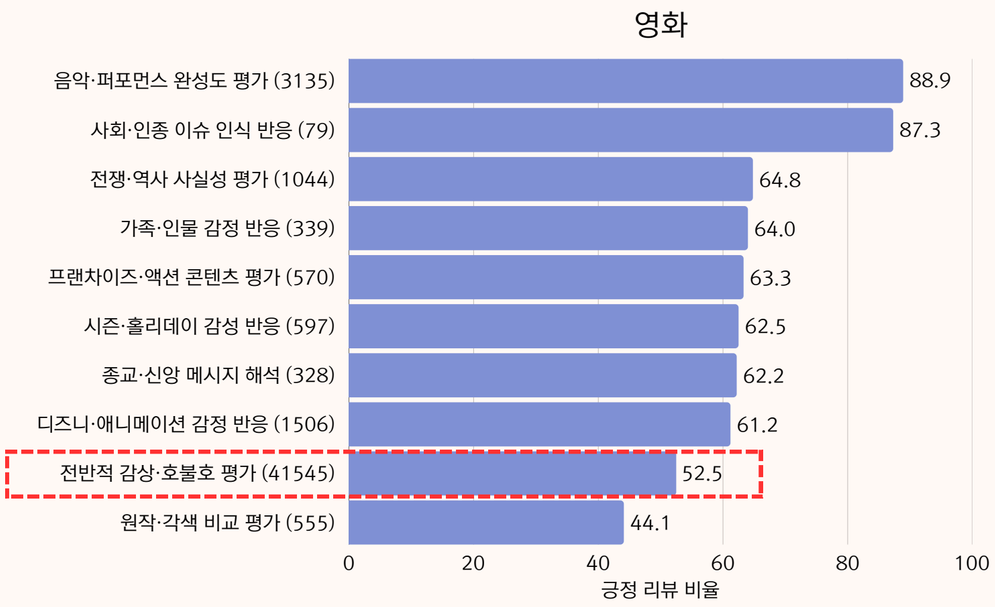


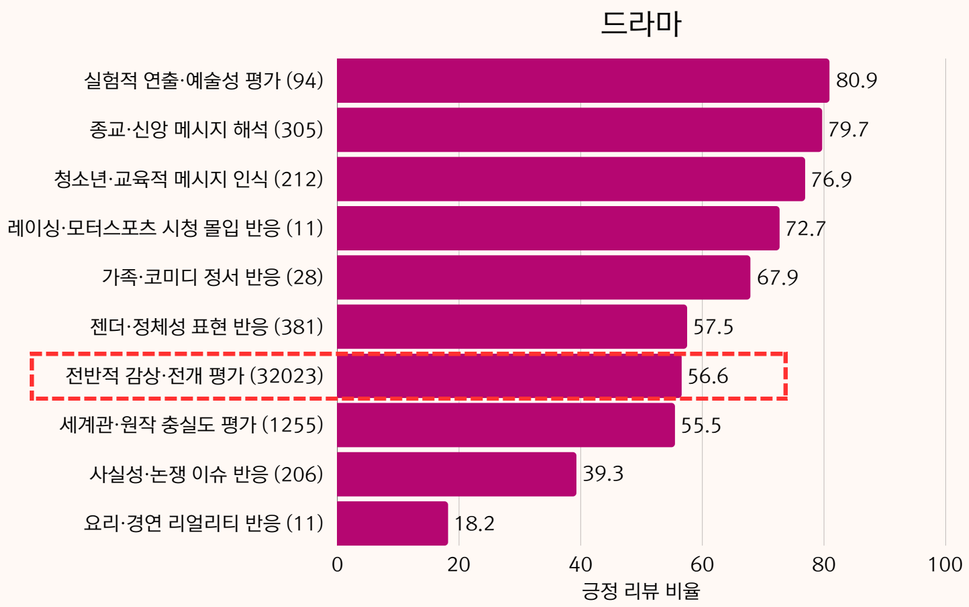


- 영화와 드라마는 리뷰 감정 반응 언어의 초점이 명확히 다름
- 영화 리뷰는 **관람 중 체감 요소**(연출·퍼포먼스)에 대한 긍정 반응이 높음
- 드라마 리뷰는 **사회적 의미와 메시지 해석**에 대한 긍정 반응이 높음
- **전반적 감상** 클러스터에 **가장 많은 리뷰**가 집중됨

05

# 데이터 분석 리뷰 심층 분석

## 영화/드라마 전반적 감상 클러스터 분석

### 긍정 리뷰 키워드

beautiful · fun · enjoyable · funny
perfect · great · original

보는 재미와 몰입 가능한 엔터테인먼트 경험에 대한 평가

VS

### 부정 리뷰 키워드

boring · slow · terrible · worst
disappointing · waste · bad

전개 속도와 기대 대비 만족도 차이에 반응

- 가장 많은 리뷰가 집중된 '전반적 감상' 클러스터는 **작품에 대한 전체 만족·불만을 직접적**으로 드러냄
- 전반적 감상의 호불호는 **작품의 메시지**보다 관람 중 느껴지는 **재미와 몰입도**에서 형성됨

05

# 데이터 분석 SUMMARY

## 장르별 흥행율 분석

- 역사, 정치 등 거대 서사를 기반으로 한 작품에서 흥행 비중이 높음
- 공포나 소프 드라마처럼 구조가 단순, 반복적인 장르는 흥행 비중 낮음

## 줄거리 및 장르 키워드 분석

- 흥행 영화는 판타지 어드벤처와 SF 계열이 상위 비중을 차지
- 비흥행 영화는 코미디, 액션, 공포 장르로 클러스터링
- 흥행 드라마는 로맨스 코미디, 스릴러 장르가 상위 비중
- 비흥행 드라마는 서사 구조가 명확하지 않음
- 드라마는 영화보다 클러스터 종류가 적음

## 줄거리 키워드 분석

- 전쟁이나 정치 등 진중한 요소에 관련된 어휘가 흥행작에서 자주 등장
- 사랑이나 친구 등 관계에 관한 어휘가 비흥행작에서 자주 등장
- 사건보다 관계 중심 작품들의 비흥행
- 흥행/비흥행 장르적 특징이 어휘 차이에 등장
- 특히 비흥행 작품들의 장르적 특성이 반영

## 리뷰 심층 분석

- 영화는 음악·퍼포먼스 등 체감 완성도 중심으로 평가됨
- 드라마는 메시지와 연출 의도 등 의미 해석 중심으로 평가가 나뉨
- 대중적 호불호는 메시지보다 보는 재미와 관람 몰입도에서 결정됨

06

# 머신러닝 흥행 예측 모델링 - 피처 선택

## 타겟 변수

**흥행 이진 변수**

- 흥행을 상위 20%, 비흥행을 하위 40%로 라벨링 (중간층은 제거)

## 종속 변수

**임베딩 데이터**

- 장르 및 줄거리를 QWEN-3 모델을 통해 임베딩하여 정량화 (1024차원)

**인코딩 데이터**

- 장르: 멀티 라벨 인코딩
- 언어/국가 : 원핫 인코딩

**기타 메타데이터**

- 개봉월(영화), 방영월(드라마): 월 변환 → 순환 인코딩

06

# 머신러닝 흥행 예측 모델링 - 학습

## 이진 분류

- 콘텐츠 흥행 여부를 확률(0~1)로 예측하는 이진 분류 문제로 설정

## 클래스 불균형 완화

- 영화·드라마 데이터에서 흥행 작품이 소수 클래스(약 1:2 비율)
- 흥행 클래스에 가중치를 적용해 불균형 문제를 완화하며 학습

## 모델 다양화

- 트리 기반 모델(LightGBM, XGBoost): 예측 안정성 확보, 피처 중요도 해석의 일관성을 검증
- 신경망 모델(MLP): 비선형 패턴 학습, 임베딩 활용 효과 분석
- 앙상블 모델: Soft Voting으로 균형 잡힌 예측 모델 구성

## 튜닝을 통한 모델 성능 개선

- 흥행 작품을 놓치지 않는 것이 중요해 Precision과 Recall의 균형을 고려한 F1 기준 사용
- 임계값 조정 및 하이퍼파라미터 튜닝으로 모델 성능 추가 개선

* Soft Voting 앙상블: 여러 모델의 예측 확률을 평균해 안정적인 최종 예측을 수행하는 방식

06

# 머신러닝 흥행 예측 모델링 - 성능 비교

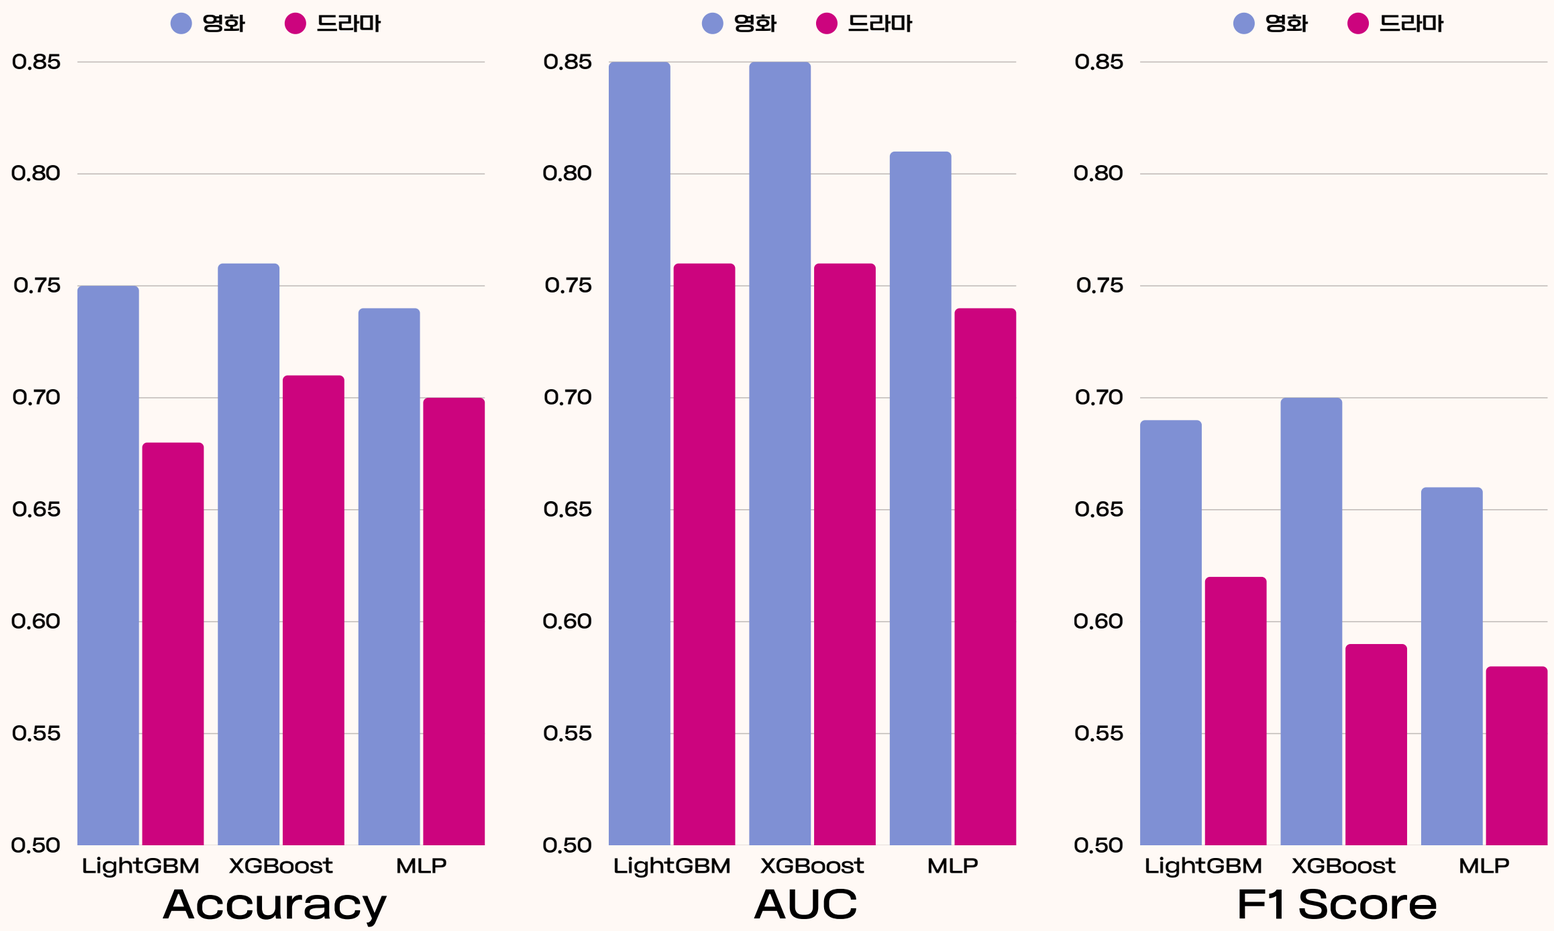


**영화**

- XGBoost가 전체적으로 우수
- LightGBM는 AUC 기준 동급 상위권

**드라마**

- 정확도는 XGBoost가, F1 기준 실질 성능은 LightGBM이 우수
- 트리 기반 모델(LightGBM, XGBoost)은 임베딩 기반 흥행 예측에서 안정적인 성능을 보였음
  → 단순히 정확도만 높이기보다, 흥행 가능작을 놓치지 않도록 설계

06

# 머신러닝 흥행 예측 모델링 - SHAP value 결과

## 영화

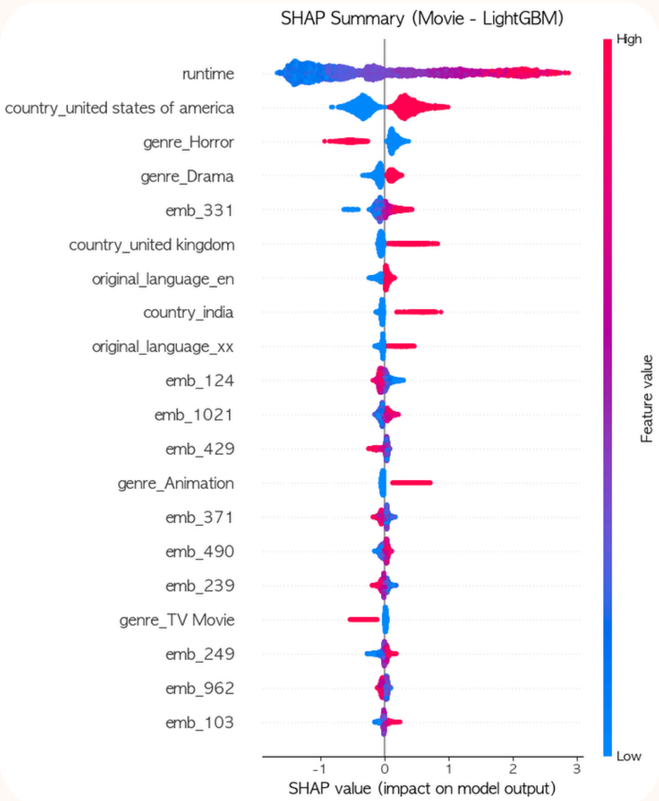


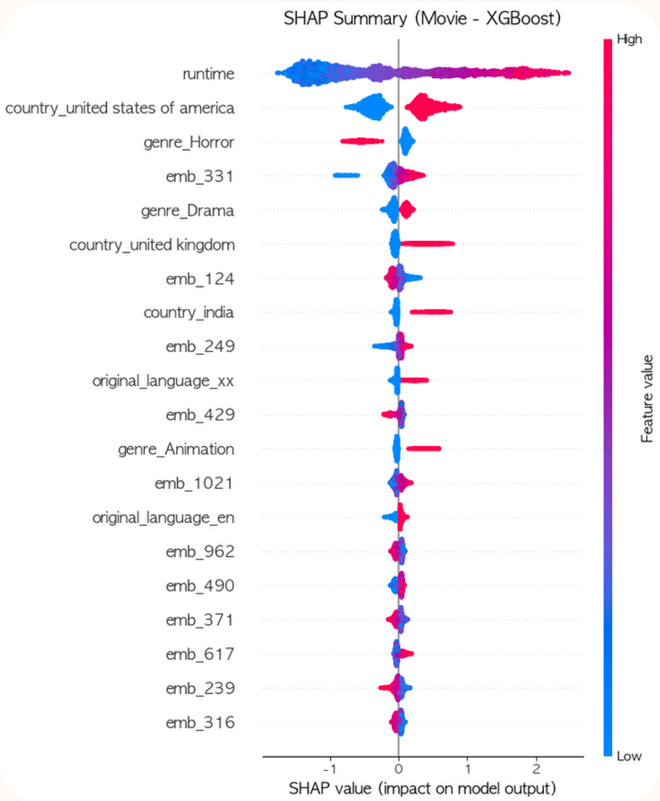


- 영화에서는 **러닝타임이 길수록 흥행**, 호러 장르일수록 비흥행 쪽으로 작용하고, 제작 국가(미국)도 중요한 신호로 쓰임
- 상영 시간과 장르, 제작 국가뿐 아니라, **서사도 중요한 흥행 지표**임을 시사
- 모델 간 SHAP value가 일관적으로 작용

06

# 머신러닝 흥행 예측 모델링 - SHAP value 결과

## 드라마

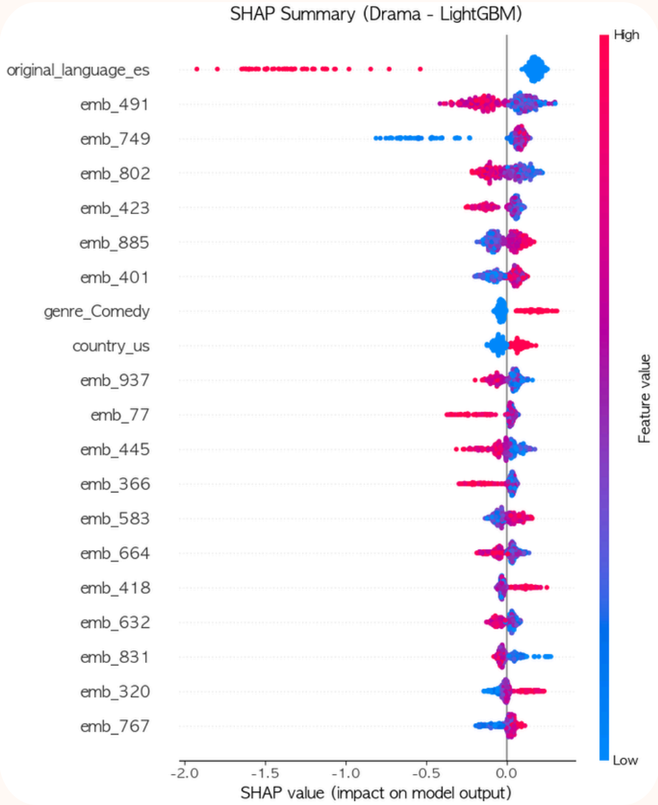


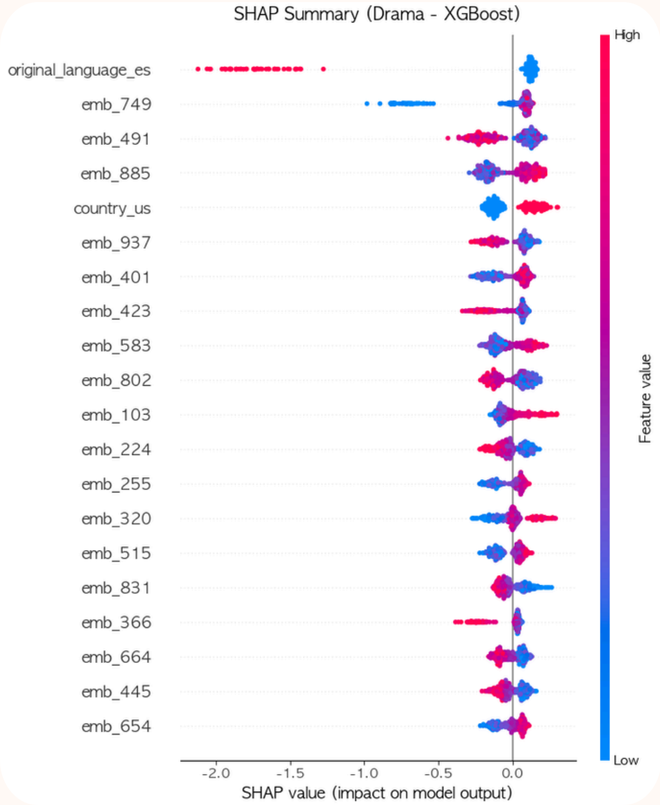


- 스페인어가 비흥행의 요소
  → 텔레노벨라 장르의 신호
- 코미디 장르가 흥행의 요소
- **서사도 중요한 흥행 지표**임을 확인
- SHAP value가 일관적으로 작용

* 텔레노벨라(Telenovela): 사랑·가족·갈등을 중심으로 전개되는 중남미권 연속 드라마 장르

06

# 머신러닝 흥행 예측 모델링 - 앙상블 모델 구축

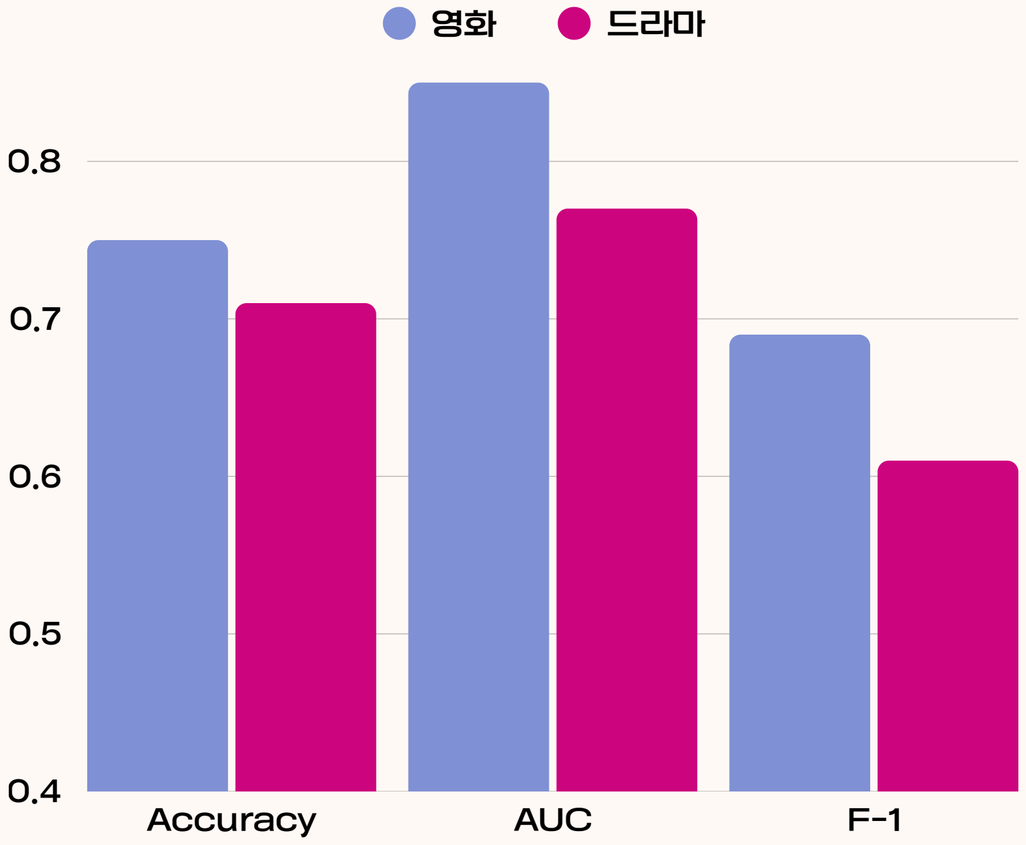


## 모델 성능 개선용 Soft Voting 모델

- **영화 앙상블**은 AUC 0.85, F1 0.69, Accuracy 0.75로 단일 모델과 비슷한 AUC를 유지하면서 **F1을 소폭 끌어올림**
- **드라마 앙상블**은 AUC 0.77, F1 0.61, Accuracy 0.71로, 단일 모델 대비 **약간의 성능 향상**과 보다 **안정적인 예측**을 보여줌
- **영화**에서는 흥행 기준이 되는 임계값을 낮춰(Threshold: 0.27) **흥행 후보를 더 넓게** 잡았고, **드라마**에서는 영화보다 **다소 엄격한 기준** (Threshold: 0.33)으로 흥행/비흥행 분류
- **Soft Voting 앙상블**이 각 모델의 장점을 합쳐 극단적인 오판을 줄이고 **균형 잡힌 성능**을 내는 방향으로 작동

06

# 머신러닝 흥행 예측 모델링 - 요약

**영화**

러닝타임은 일정 시간 이상 확보할수록, 제작 국가는 미국일수록 흥행에 유리하며, 호러 장르는 비흥행 경향을 보임

**드라마**

제작 언어가 스페인어인 경우 비흥행 경향을 보였고,
장르가 코미디일수록 흥행 확률이 높아지는 경향이 나타남

**공통**

영화와 드라마 모두에서 서사 구조와 장르 특성이 흥행 확률에 유의한 영향을 미치는 것으로 나타남

07

# 결론

## 인사이트

| | | | | |
|---|---|---|---|---|
| 콘텐츠 흥행은 우연 아닌 서사 구조로 설명·예측 가능 | 영화와 드라마는 서로 다른 흥행 논리를 가짐 | 흥행작은 갈등의 축적과 인물 변화를 명확히 보임 | 비흥행의 원인은 서사 부재가 아닌 구조적 모호성 | 서사 분석은 흥행 판단의 정량적 도구가 될 수 있음 |

## 비즈니스 솔루션

- 제작·구매·투자 전 단계에 시놉시스만으로 흥행 가능성 예측
- 의사결정 리스크를 사전에 최소화하는 데이터 기반 기준 제공

## 향후 계획

- 텍스트 분석에 포스터·트레일러·배우 네트워크를 결합한 멀티모달 확장
- 모델의 설명력과 흥행 예측 성능을 추가로 강화

07

# 결론

## 영화/드라마 흥행 공식

### 영화

- 명확한 장르, 역사, 정치 등 거대 서사
- 서사의 밀도를 반영하는 러닝타임 확보
- 미장센/조명/음악 등 영상 제작 퀄리티 보장
- 일상코미디, 좀비 아포칼립스 등 클리셰적이고 반복적인 영화는 지양

### 드라마

- 명확한 장르
- 진중한 토픽 중심의 서사
- 가족 복수극, 멜로 등 감정 중심은 지양
- 완성도 있는 코미디 장르 공략
- 체감 경험 극대화 전략

07

# 결론

## 분석의 한계점

- 드라마 데이터의 부족해 영화 대비 변동성이 다소 크게 나타날 수 있다는 한계
- 줄거리 길이가 짧은 작품이 많아 흥행 예측하기에 충분한 정보가 임베딩에 반영되지 못했을 가능성
- 배우나 캐스팅 파워 요소를 결합한다면 흥행 예측의 설명력과 현실성이 더욱 강화될 것으로 기대

→ 본 분석 결과는 흥행 가능성에 대한 보조적 의사결정 도구로 활용하는 것이 적절

08

# 대시보드 제작

**개요**

Streamlit 기반 인터랙티브 분석 시스템 제작

**대상**

OTT 콘텐츠 기획·제작·투자 의사결정자

**구성**

Page 1 흥행 트렌드 파악

- 목적: “지금 어떤 콘텐츠가, 왜, 얼마나 잘 되고 있는가?” 확인
- 내용: 핵심 흥행 지표, 연도별 흥행 트렌드, OTT별 흥행작 점유율, 상위 흥행 콘텐츠 Top 5

Page 2 흥행 요인 분석

- 목적: “어떤 특성이 흥행/비흥행을 만드는가?” 파악
- 내용: 흥행작/비흥행작의 키워드 분석(TF-IDF, BerTopic 결과), 흥행작 영화 클러스터 Map 등

Page 3 흥행 예측

- 목적: “그래서, 무엇을 만들어야 하는가?” 제시
- 내용: 가상 제작 시나리오 흥행 시뮬레이션, 임베딩 기반 유사 콘텐츠 추천

**상세 페이지**

앱 배포 링크 바로가기 (클릭)

# 감사합니다

THANK YOU